UNIVERSITÉ MOHAMMED V DE RABAT
ÉCOLE MOHAMMADIA D'INGÉNIEURS
Département Modélisation et Informatique Scientifique
Centre Hospitalier Ibn Sina

Rapport de stage de fin de première année

DÉTECTION DU GLAUCOME À PARTIR D'IMAGES DU FOND D'ŒIL PAR APPRENTISSAGE PROFOND

Étude comparative de ResNet50 et de ViT-B/16
sur deux jeux de données

Réalisé par :
Lassine SAVANE

Encadré par :

Pr BENHLIMA Laila (EMI) : Encadrante académique
Pr EL HACHEMI Rim (Centre Hospitalier Ibn Sina) : Encadrante professionnelle

Stage effectué au Centre Hospitalier Ibn Sina (Hôpital des Spécialités), Rabat
du 9 juillet 2026 au 9 septembre 2026

Date de remise du rapport : ....17 Novembre 2026.....

Année universitaire : 2025–2026

Table des matières

Liste des figures vi

Liste des tableaux vii

Liste des abréviations viii

Introduction générale 1

1 Contexte médical et problématique du glaucome 4
- 1.1 Le glaucome . . . 4
  - 1.1.1 Définition et physiopathologie . . . 4
  - 1.1.2 Formes cliniques . . . 4
  - 1.1.3 Épidémiologie et facteurs de risque . . . 5
- 1.2 Diagnostic et dépistage . . . 5
  - 1.2.1 Démarche diagnostique . . . 5
  - 1.2.2 Signes papillaires visibles sur le fond d'œil . . . 5
  - 1.2.3 Importance du dépistage précoce . . . 6
- 1.3 Les images du fond d'œil . . . 6
- 1.4 Détection assistée par apprentissage profond . . . 6
- 1.5 Problématique et positionnement du travail . . . 6

2 Fondements théoriques et architectures étudiées 8
- 2.1 Apprentissage automatique et apprentissage profond . . . 8
  - 2.1.1 Définitions . . . 8
  - 2.1.2 Neurone artificiel et réseau multicouche . . . 9
  - 2.1.3 Fonction de perte . . . 9
  - 2.1.4 Optimisation . . . 9
  - 2.1.5 Généralisation et régularisation . . . 9
- 2.2 Réseaux de neurones convolutifs et ResNet50 . . . 10
  - 2.2.1 Convolution et pooling . . . 10
  - 2.2.2 ResNet50 et connexions résiduelles . . . 10
- 2.3 Transformers de vision (ViT) . . . 11
- 2.4 RETFound et les modèles de fondation rétiniens . . . 12
- 2.5 Apprentissage par transfert . . . 13
- 2.6 Métriques d'évaluation . . . 13
  - 2.6.1 Matrice de confusion et métriques dérivées . . . 13

2.6.2 Courbe ROC et AUC . . . 14
2.6.3 Perte et suivi de l'entraînement . . . 14
2.6.4 Incertitude statistique des estimations . . . 15

3 Datasets et méthodologie expérimentale 16
3.1 Démarche expérimentale générale . . . 16
3.2 Jeux de données . . . 17
3.2.1 ACRIMA . . . 17
3.2.2 AI Glaucoma Dataset for AI Diagnosis . . . 17
3.2.3 Partition des données . . . 17
3.3 Prétraitement des images . . . 17
3.3.1 Pipeline sans prétraitement . . . 17
3.3.2 Égalisation adaptative d'histogramme (CLAHE) . . . 17
3.3.3 Recadrage et normalisation . . . 18
3.4 Modèles et protocole d'entraînement . . . 18
3.5 Protocole d'évaluation . . . 18
3.6 Environnement logiciel et reproductibilité . . . 19
3.7 Limites méthodologiques . . . 19

4 Résultats expérimentaux sur ACRIMA 20
4.1 Configuration expérimentale sur ACRIMA . . . 20
4.1.1 Composition du dataset et partition des données . . . 20
4.1.2 Prétraitement des images . . . 21
4.1.3 Paramètres d'entraînement . . . 21
4.2 Résultats du ResNet50 . . . 21
4.2.1 Courbes d'apprentissage . . . 21
4.2.2 Performances sur le jeu de test . . . 22
4.3 Résultats du ViT-B/16 pré-entraîné sur ImageNet [18] . . . 24
4.3.1 Courbes d'apprentissage . . . 24
4.3.2 Performances sur le jeu de test . . . 24
4.4 Comparaison des deux modèles sur ACRIMA . . . 26
4.4.1 Synthèse des métriques . . . 26
4.4.2 Analyse métrique par métrique . . . 26
4.4.3 Incertitude statistique . . . 27
4.5 Démonstration qualitative de prédictions individuelles . . . 27
4.5.1 Dispositif d'acquisition . . . 27
4.5.2 Prédictions des deux modèles . . . 27
4.6 Limites propres à ACRIMA . . . 30
4.7 Conclusion partielle . . . 30

5 Résultats expérimentaux sur le second dataset 32
5.1 Configuration expérimentale sur le second dataset . . . 32
5.1.1 Composition du dataset et partition des données . . . 32
5.1.2 Prétraitement des images . . . 33
5.1.3 Modèles et paramètres d'entraînement . . . 33

5.2 Résultats du ResNet50 33
5.2.1 Courbes d'apprentissage 33
5.2.2 Performances sur le jeu de test 35
5.3 Résultats du ViT-B/16 35
5.3.1 Courbes d'apprentissage 35
5.3.2 Performances sur le jeu de test 35
5.4 Fiabilité des étiquettes et discussion 35
5.5 Conclusion partielle 38

6 Discussion générale et conclusion **39**
6.1 Discussion transversale 39
6.2 Conclusion générale et perspectives 39

Bibliographie **41**

Table des figures

1.1 Représentation schématique d'une papille normale et d'une papille glaucomateuse (valeurs de CDR illustratives) 5

2.1 Structure générale d'un réseau convolutif de classification 10
2.2 Bloc résiduel de type *bottleneck* de ResNet50 11
2.3 Principe du Vision Transformer appliqué à la classification d'images . . 11
2.4 Pré-entraînement auto-supervisé par auto-encodeur à masquage (MAE) 13

3.1 Démarche expérimentale appliquée à chaque jeu de données 16

4.1 Image ACRIMA avant (à gauche) et après (à droite) prétraitement par CLAHE et recadrage 21
4.2 Courbes d'apprentissage du ResNet50 sans prétraitement sur ACRIMA 22
4.3 Courbes d'apprentissage du ResNet50 avec prétraitement sur ACRIMA 22
4.4 Matrices de confusion du ResNet50 sur le jeu de test d'ACRIMA, sans et avec prétraitement 23
4.5 Courbes ROC du ResNet50 sur le jeu de test d'ACRIMA, sans et avec prétraitement 23
4.6 Courbes d'apprentissage du ViT-B/16 sur ACRIMA : perte, exactitude et AUC de validation 24
4.7 Matrices de confusion du ViT-B/16 sur le jeu de test d'ACRIMA . . . 25
4.8 Courbes ROC du ViT-B/16 sur le jeu de test d'ACRIMA, sans et avec prétraitement 25
4.9 Rétinographe Canon utilisé pour l'acquisition des images du fond d'œil (arrière-plan partiellement flouté) 28
4.10 Poste d'acquisition affichant une image du fond d'œil 28
4.11 Image externe testée et résultats de prédiction sur ACRIMA 29

5.1 Image du second dataset avant (à gauche) et après (à droite) prétraitement par CLAHE et recadrage 34
5.2 Courbes d'apprentissage du ResNet50 sans prétraitement sur le second dataset 34
5.3 Courbes d'apprentissage du ResNet50 avec prétraitement sur le second dataset 34
5.4 Matrices de confusion du ResNet50 sur le jeu de test (second dataset) . 35
5.5 Courbes ROC et performances du ResNet50 sur le second dataset . . . 36
5.6 Courbes d'apprentissage du ViT-B/16 sur le second dataset 36

5.7 Matrices de confusion du ViT-B/16 sur le jeu de test 37
5.8 Courbes ROC et métriques du ViT-B/16 sur le second dataset 37

6.1 Synthèse globale de la comparaison des performances sur les deux datasets 39

Liste des tableaux

2.1 Caractéristiques des architectures évoquées 12

3.1 Configuration d'entraînement des deux modèles 19

4.1 Effectifs d'ACRIMA et partition utilisée 20
4.2 Métriques de test du ResNet50 sur ACRIMA 23
4.3 Métriques de test du ViT-B/16 sur ACRIMA 25
4.4 Synthèse des performances de test sur ACRIMA 26
4.5 Intervalles de confiance à 95 % des métriques de test (ACRIMA) 27
4.6 Probabilités de glaucome sur l'image externe testée 29

5.1 Effectifs du second dataset et partition utilisée 33

Liste des abréviations

AUC	*Area Under the Curve*, aire sous la courbe ROC
BCE	*Binary Cross-Entropy*, entropie croisée binaire
CDR	*Cup-to-Disc Ratio*, rapport excavation / papille
CLAHE	*Contrast Limited Adaptive Histogram Equalization*, égalisation adaptative d'histogramme à contraste limité
CNN	*Convolutional Neural Network*, réseau de neurones convolutif
FN, FP	Faux négatifs, faux positifs
G1020	Base d'images de fond d'œil pour la détection du glaucome [33]
IC	Intervalle de confiance
MAE	*Masked AutoEncoder*, auto-encodeur à masquage
ORIGA	Base d'images de fond d'œil ORIGA-light [34]
PIO	Pression intraoculaire
REFUGE	*Retinal Fundus Glaucoma Challenge* [35]
ROC	*Receiver Operating Characteristic*
ViT	*Vision Transformer*
VN, VP	Vrais négatifs, vrais positifs
VPN	Valeur prédictive négative

Introduction générale

Contexte et problématique

Le glaucome est une neuropathie optique chronique et progressive, caractérisée par la perte irréversible des cellules ganglionnaires de la rétine et de leurs axones [1]. Silencieux aux stades précoces, il constitue l'une des principales causes de cécité irréversible dans le monde [2]. Les traitements disponibles visent à ralentir la progression de la maladie sans pouvoir restaurer la vision perdue : la précocité du diagnostic conditionne donc directement le pronostic visuel des patients.

La photographie du fond d'œil (rétinographie), peu invasive et de plus en plus accessible, permet d'observer la papille optique, dont l'aspect (élargissement de l'excavation, amincissement de l'anneau neurorétinien) constitue un signe clé du glaucome. L'interprétation de ces images dépend toutefois de l'expérience de l'examinateur et mobilise des ressources spécialisées limitées. Les progrès de l'apprentissage profond en analyse d'images médicales [4] ont ainsi suscité de nombreux travaux sur la détection automatique du glaucome à partir de photographies du fond d'œil [5, 6, 7]. Deux familles d'architectures dominent ces approches : les réseaux de neurones convolutifs, dont ResNet50 [17] est un représentant classique, et les transformers de vision [20]. Leur comparaison sur des images rétiniennes, de qualité variable et disponibles en quantité limitée, constitue la problématique de ce travail.

Organisme d'accueil et déroulement du stage

Le stage de recherche, d'une durée de deux mois (du 9 juillet au 9 septembre 2026), s'est déroulé au Centre Hospitalier Ibn Sina de Rabat, qui regroupe plusieurs structures hospitalières dont l'Hôpital des Spécialités. Il a été encadré sur le plan académique par le Pr BENHLIMA Laila (École Mohammadia d'Ingénieurs) et sur le plan professionnel par le Pr EL HACHEMI Rim. Il a notamment permis d'observer le dispositif d'acquisition des images du fond d'œil utilisé en pratique clinique (rétinographe et poste d'acquisition, présentés au chapitre 4).

Objectifs

L'objectif général est de réaliser une **étude comparative des performances de ResNet50 et d'un Vision Transformer ViT-B/16 pour la détection du glaucome à partir d'images du fond d'œil**, dans deux environnements

expérimentaux distincts correspondant à deux jeux de données. Les objectifs spécifiques sont les suivants :

- présenter les fondements médicaux et théoriques nécessaires à la compréhension du travail ;
- construire un protocole expérimental reproductible reposant sur le transfert d'apprentissage ;
- évaluer l'effet d'un prétraitement des images (égalisation adaptative d'histogramme CLAHE et recadrage) en comparant, pour chaque modèle, les images brutes et les images traitées ;
- analyser les résultats avec des métriques adaptées au dépistage (sensibilité, spécificité, F1, AUC) et en tenant compte de leur incertitude ;
- identifier les limites de l'étude, en particulier celles liées à la qualité des étiquettes des jeux de données.

Trois hypothèses de travail guident l'étude : (H1) le prétraitement améliore les performances de classification ; (H2) le ViT-B/16 obtient des performances au moins équivalentes à celles du ResNet50 ; (H3) les performances relatives des modèles sont cohérentes d'un jeu de données à l'autre.

Le périmètre est volontairement borné : le travail porte exclusivement sur la **classification binaire** (glaucome / sain) à partir de photographies du fond d'œil. Il ne comporte ni stadification de la sévérité, ni segmentation de la papille. Par ailleurs, RETFound [22], modèle de fondation pré-entraîné sur des images rétiniennes, est étudié sur le plan théorique et envisagé comme perspective ; les expériences utilisent un ViT-B/16 pré-entraîné sur ImageNet [18].

Travail réalisé, méthodologie et difficultés

Huit entraînements ont été réalisés : deux modèles (ResNet50 et ViT-B/16), deux jeux de données (ACRIMA et AI Glaucoma Dataset for AI Diagnosis) et deux pipelines (images brutes et images prétraitées). Chaque configuration est évaluée sur un jeu de test indépendant avec l'exactitude, la sensibilité, la spécificité, la précision, le score F1, l'AUC, les matrices de confusion et les courbes ROC. Une démonstration qualitative sur une image externe acquise au Centre Hospitalier Ibn Sina complète l'évaluation sur ACRIMA.

Les principales difficultés rencontrées sont de deux ordres. D'une part, la taille limitée des jeux de test (106 images pour ACRIMA, dont 47 saines) impose la prudence dans l'interprétation des écarts. D'autre part, l'examen de la structure du second jeu de données a révélé un risque de contamination des étiquettes (doublons, images saines étiquetées « glaucome »), dont la vérification et la correction sont proposées sans avoir pu être réalisées dans le temps imparti.

Plan du rapport

Le rapport est organisé en six chapitres. Le chapitre 1 présente le contexte médical et la problématique. Le chapitre 2 expose les fondements théoriques de l'apprentissage

profond et les architectures étudiées. Le chapitre 3 décrit les jeux de données et la méthodologie expérimentale. Les chapitres 4 et 5 présentent les résultats et les comparaisons des deux modèles sur ACRIMA puis sur le second jeu de données. Le chapitre 6 propose une discussion générale et une comparaison transversale. Une conclusion générale et des perspectives achèvent le rapport.

Chapitre 1

Contexte médical et problématique du glaucome

Ce chapitre présente le glaucome sous l'angle médical : définition, formes cliniques, épidémiologie et facteurs de risque, puis démarche diagnostique et intérêt du dépistage précoce. Il décrit ensuite les images du fond d'œil et leurs limites, avant de situer les approches d'apprentissage profond dans l'aide au dépistage. Il se conclut par la problématique du travail.

1.1 Le glaucome

1.1.1 Définition et physiopathologie

Le glaucome désigne un groupe de neuropathies optiques chroniques et progressives caractérisées par la dégénérescence des cellules ganglionnaires de la rétine et de leurs axones, qui forment le nerf optique [1]. Cette perte neuronale se traduit par une modification structurale de la papille optique, avec un élargissement de l'excavation centrale et un amincissement de l'anneau neurorétinien, ainsi que par une perte progressive du champ visuel, d'abord périphérique puis centrale aux stades avancés. La pression intraoculaire (PIO) élevée est le principal facteur de risque modifiable, et son abaissement est le seul traitement dont l'efficacité est établie [1]. Elle n'est toutefois ni nécessaire ni suffisante : certains patients développent un glaucome à pression normale, tandis que certains sujets à pression élevée n'en développent pas. Les mécanismes mécaniques (contraintes au niveau de la lame criblée) et vasculaires (perfusion du nerf optique) invoqués pour expliquer la souffrance des axones font encore l'objet de débats [2].

1.1.2 Formes cliniques

Le glaucome primitif à angle ouvert est la forme la plus répandue. Le glaucome par fermeture de l'angle, dont l'évolution peut être aiguë, représente une part plus importante des cas dans les populations asiatiques [3]. Les glaucomes secondaires,

consécutifs à une autre affection oculaire ou à un traitement, et les glaucomes congénitaux complètent la classification.

1.1.3 Épidémiologie et facteurs de risque

La prévalence mondiale du glaucome chez les personnes de 40 à 80 ans est estimée à 3,54 %, soit environ 64,3 millions de personnes en 2013. Les projections atteignent 76,0 millions en 2020 et 111,8 millions en 2040 [3]. Les principaux facteurs de risque sont l'âge, la PIO élevée, les antécédents familiaux, l'origine ethnique, la myopie forte et une faible épaisseur cornéenne centrale [1].

1.2 Diagnostic et dépistage

1.2.1 Démarche diagnostique

Le diagnostic repose sur un faisceau d'examens complémentaires : mesure de la PIO (tonométrie), examen de l'angle irido-cornéen (gonioscopie), mesure de l'épaisseur cornéenne (pachymétrie), examen du champ visuel (périmétrie), évaluation de la papille et de la couche des fibres nerveuses rétiniennes (RNFL) par tomographie en cohérence optique (OCT) et examen du fond d'œil [1]. Aucun de ces examens n'est suffisant isolément ; leur combinaison et le suivi dans le temps sont nécessaires.

1.2.2 Signes papillaires visibles sur le fond d'œil

L'examen de la papille sur le fond d'œil fournit des signes structuraux évocateurs de glaucome : élargissement de l'excavation (*cup*) par rapport au disque optique (*disc*), mesuré par le rapport excavation/papille vertical (CDR, *cup-to-disc ratio*), amincissement de l'anneau neurorétinien, hémorragies du bord papillaire, atrophie péripapillaire et défauts de la couche des fibres nerveuses. La figure 1.1 illustre schématiquement l'élargissement de l'excavation. L'interprétation de ces signes comporte une part de subjectivité, la variabilité entre examinateurs étant documentée dans la littérature.

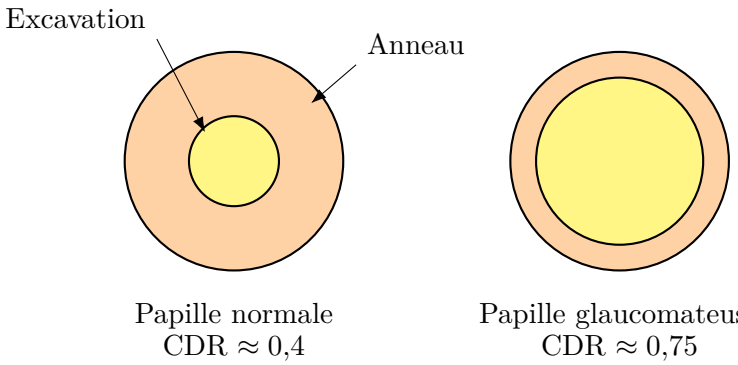


FIGURE 1.1 – Représentation schématique d'une papille normale et d'une papille glaucomateuse (valeurs de CDR illustratives)

1.2.3 Importance du dépistage précoce

Le caractère asymptomatique des stades précoces et l'irréversibilité des lésions expliquent qu'une part importante des cas soit diagnostiquée tardivement. Un diagnostic précoce permet d'instaurer un traitement qui ralentit la progression de la maladie [1]. Or le dépistage par un bilan spécialisé complet est coûteux et dépend d'une offre d'ophtalmologues inégalement répartie. Cette contrainte motive le développement d'outils d'aide au dépistage fondés sur un examen simple et rapide, comme la photographie du fond d'œil.

1.3 Les images du fond d'œil

La rétinographie consiste à photographier la rétine, la papille optique, la macula et les vaisseaux au moyen d'un rétinographe. Elle produit une image couleur dont l'aspect dépend de l'appareil, du réglage et des conditions d'examen. Plusieurs facteurs dégradent la qualité des images : éclairage non uniforme, faible contraste, flou, reflets, artefacts, opacités des milieux oculaires. À ces facteurs s'ajoute une variabilité entre appareils et centres (teinte, résolution, champ photographié, recadrage), qui peut dégrader les performances d'un modèle lorsqu'il est appliqué à des images différentes de celles de son entraînement. Cette variabilité justifie l'étude de techniques de prétraitement (chapitre 3) et l'évaluation sur plusieurs jeux de données.

1.4 Détection assistée par apprentissage profond

Des systèmes d'apprentissage profond ont été développés pour détecter, à partir de photographies du fond d'œil, plusieurs affections rétiniennes, dont le glaucome suspect [5]. Un système entraîné sur plus de 48 000 photographies pour détecter la neuropathie optique glaucomateuse rapporte une AUC de 0,986 [6]. Un réseau ensembliste exploitant la région du disque optique a été proposé pour le dépistage du glaucome [8]. Plusieurs CNN pré-entraînés ont par ailleurs été validés de manière approfondie pour l'évaluation du glaucome, ce travail ayant donné lieu à la diffusion de la base ACRIMA, utilisée ici [7].

Ces travaux soulèvent plusieurs difficultés récurrentes : taille limitée des jeux annotés, hétérogénéité des sources, qualité des étiquettes, sensibilité aux changements d'appareil, et validation clinique prospective rarement disponible. L'utilisation de modèles pré-entraînés et le transfert d'apprentissage (chapitre 2) répondent en partie à la rareté des données annotées.

1.5 Problématique et positionnement du travail

Dans ce contexte, la question traitée est la suivante : *comment se comparent, pour la détection binaire du glaucome sur photographies du fond d'œil, un réseau convolutif (ResNet50) et un transformer de vision (ViT-B/16) adaptés par transfert*

d'apprentissage, et quel est l'effet d'un prétraitement d'image sur leurs performances ? Cette question est examinée sur deux jeux de données, afin de distinguer ce qui relève d'un jeu particulier de ce qui se retrouve dans les deux environnements. Les chapitres suivants présentent les fondements théoriques nécessaires, la méthodologie, puis les résultats.

Chapitre 2

Fondements théoriques et architectures étudiées

Ce chapitre expose les notions théoriques nécessaires à la compréhension des expériences : principes de l'apprentissage profond et de l'optimisation, réseaux convolutifs et architecture ResNet50, transformers de vision (ViT), modèle de fondation RETFound, apprentissage par transfert et métriques d'évaluation des modèles de classification. Les architectures utilisées dans les expériences (ResNet50 et ViT-B/16) y sont présentées avec leurs fondements mathématiques ; RETFound est présenté pour situer le ViT-B/16 par rapport à un modèle pré-entraîné spécifiquement sur des images rétiniennes.

2.1 Apprentissage automatique et apprentissage profond

2.1.1 Définitions

L'intelligence artificielle regroupe les méthodes permettant à une machine de simuler des capacités cognitives (perception, raisonnement, décision). L'apprentissage automatique en est un sous-domaine dans lequel un modèle apprend à partir de données, sans que les règles de décision soient programmées explicitement. L'apprentissage profond (*deep learning*) est un sous-domaine de l'apprentissage automatique fondé sur des réseaux de neurones à nombreuses couches, capables d'apprendre des représentations hiérarchiques des données [9, 10]. Pour la classification supervisée, il s'agit de trouver les paramètres θ d'une fonction f_θ qui minimisent une perte moyenne sur un jeu d'apprentissage $\{(x_i, y_i)\}_{i=1}^{N}$:

$$\theta^* = \arg\min_{\theta} \frac{1}{N} \sum_{i=1}^{N} \mathcal{L}\Big(f_\theta(x_i), y_i\Big) \tag{2.1}$$

2.1.2 Neurone artificiel et réseau multicouche

Un neurone artificiel calcule une somme pondérée de ses entrées $\mathbf{x}$, à laquelle s'ajoute un biais b, puis applique une fonction d'activation non linéaire g :

$$z = \mathbf{w}^\top \mathbf{x} + b, \qquad a = g(z) \tag{2.2}$$

Les activations usuelles sont la sigmoïde $\sigma(z) = 1/(1+e^{-z})$, qui produit une probabilité dans $[0,1]$ en sortie d'un classifieur binaire, et la fonction ReLU $g(z) = \max(0,z)$, très utilisée dans les couches cachées. Dans un perceptron multicouche, les neurones sont organisés en couches successives et la sortie de la couche l s'écrit :

$$A^{[l]} = g^{[l]}\left(W^{[l]} A^{[l-1]} + b^{[l]}\right), \qquad A^{[0]} = X \tag{2.3}$$

2.1.3 Fonction de perte

En classification binaire, la perte la plus utilisée est l'entropie croisée binaire, où $\hat{y}$ désigne la probabilité prédite pour la classe positive :

$$\mathcal{L}(\hat{y}, y) = -\Big[\, y \log \hat{y} + (1-y) \log(1-\hat{y}) \,\Big] \tag{2.4}$$

Cette perte pénalise fortement une prédiction confiante mais erronée. En présence de classes déséquilibrées, chaque classe peut être pondérée. Deux formulations sont utilisées dans ce travail : des poids de classe $w_c = N/(2N_c)$ appliqués à chaque terme de la perte (option *balanced* de Keras), et un coefficient `pos_weight` $p_w = N_0/N_1$ appliqué au terme de la classe positive (PyTorch), où N_c est l'effectif de la classe c. Dans les deux cas, la classe majoritaire est sous-pondérée par rapport à la classe minoritaire.

2.1.4 Optimisation

Les paramètres sont mis à jour par descente de gradient, $\theta_{t+1} = \theta_t - \eta\, \nabla_\theta \mathcal{L}(\theta_t)$, où η est le pas d'apprentissage. Le gradient est calculé couche par couche par rétropropagation, application de la règle de dérivation en chaîne [11]. L'optimiseur Adam [13] adapte le pas de chaque paramètre à partir d'estimations des moments d'ordre un et deux du gradient. Sa variante AdamW [14] découple la décroissance des poids (*weight decay*) de la mise à jour adaptative :

$$\theta_t = \theta_{t-1} - \eta \left(\frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon} + \lambda\, \theta_{t-1} \right) \tag{2.5}$$

où $\hat{m}_t$ et $\hat{v}_t$ sont les moments corrigés du biais et λ le coefficient de décroissance des poids.

2.1.5 Généralisation et régularisation

L'objectif n'est pas de minimiser la perte sur les données d'entraînement, mais sur des données nouvelles. Lorsque l'écart entre la performance d'entraînement et celle de

validation s'accroît, le modèle est en situation de surapprentissage. Pour le limiter, plusieurs techniques sont utilisées : le *dropout*, qui désactive aléatoirement une fraction des neurones à l'entraînement [12], la décroissance des poids et l'arrêt anticipé (*early stopping*), qui interrompt l'entraînement lorsque la performance de validation cesse de s'améliorer. Les données sont réparties en trois ensembles : l'entraînement ajuste les paramètres, la validation sert à choisir des hyperparamètres ou l'époque retenue, et le test, utilisé une seule fois, estime la performance finale.

2.2 Réseaux de neurones convolutifs et ResNet50

2.2.1 Convolution et pooling

Les réseaux convolutifs (CNN, LeCun et al. [15]) exploitent la structure bidimensionnelle des images. Une couche de convolution applique des filtres K de petite taille $(k \times k)$ dont les poids, partagés sur toute l'image, sont appris :

$$(I * K)(i,j) = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} I(i+m, j+n)\, K(m,n) \tag{2.6}$$

Pour une entrée de côté n, un remplissage p et un pas s, la taille de la carte de sortie est $\lfloor (n+2p-k)/s \rfloor + 1$. Le partage des poids réduit fortement le nombre de paramètres par rapport à un réseau entièrement connecté et confère une équivariance à la translation. Les couches de *pooling* réduisent la résolution spatiale en conservant, par exemple, le maximum de chaque fenêtre. La normalisation par lots [16] stabilise l'entraînement des réseaux profonds. Empilées, ces couches extraient des motifs de plus en plus complexes : bords et textures dans les premières couches, structures anatomiques dans les couches profondes (figure 2.1).

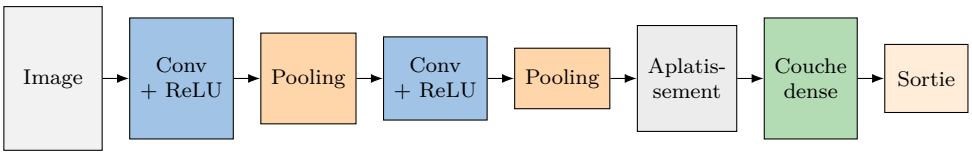


FIGURE 2.1 – Structure générale d'un réseau convolutif de classification

2.2.2 ResNet50 et connexions résiduelles

Au-delà d'une certaine profondeur, l'empilement de couches supplémentaires dégrade l'entraînement : c'est le problème de dégradation, lié notamment à la difficulté de propager le gradient dans un réseau très profond. ResNet [17] y répond en faisant apprendre à un bloc de couches non pas la transformation complète $H(x)$, mais le *résidu* $F(x) = H(x) - x$, une connexion directe (*skip connection*) reportant l'entrée x à la sortie :

$$y = F\big(x, \{W_i\}\big) + x \tag{2.7}$$

Cette connexion offre au gradient un chemin direct vers les couches profondes lors de la rétropropagation. ResNet50 est constitué d'une convolution initiale, puis de quatre étages de blocs résiduels dits *bottleneck* (au nombre de 3, 4, 6 et 3), chaque bloc enchaînant des convolutions 1×1, 3×3 et 1×1 avec normalisation par lots (figure 2.2). Il compte environ 25,6 millions de paramètres et produit, après un moyennage global spatial, un vecteur de 2 048 caractéristiques. Pré-entraîné sur ImageNet [18], il fournit des caractéristiques visuelles génériques réutilisables pour de nouvelles tâches.

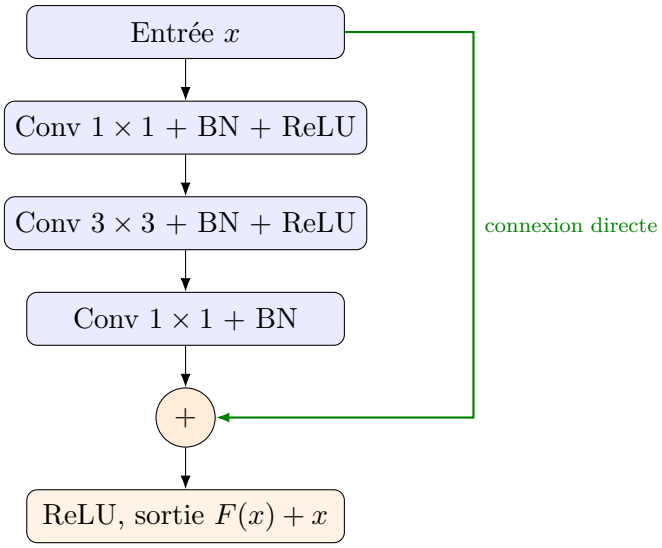


FIGURE 2.2 – Bloc résiduel de type *bottleneck* de ResNet50

2.3 Transformers de vision (ViT)

Les transformers, introduits pour le traitement du langage [19], reposent sur le mécanisme d'auto-attention. Le Vision Transformer [20] l'applique aux images en découpant l'image en N patchs de $P \times P$ pixels :

$$N = \frac{HW}{P^2} \tag{2.8}$$

Pour une image de 224×224 pixels et $P = 16$, $N = 196$ patchs. Chaque patch est aplati, projeté linéairement dans un espace de dimension D, puis additionné à un encodage de position appris. Un vecteur supplémentaire, le jeton de classe `[CLS]`, est ajouté à la séquence ; sa représentation en sortie de l'encodeur alimente la tête de classification (figure 2.3).

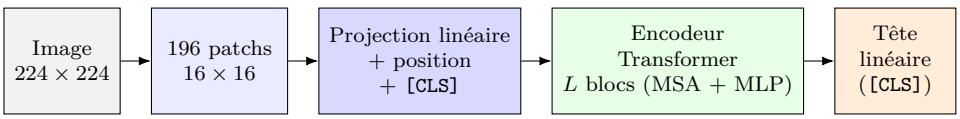


FIGURE 2.3 – Principe du Vision Transformer appliqué à la classification d'images

L'encodeur est constitué de L blocs identiques, chacun composé d'une auto-attention multi-têtes (MSA) et d'un perceptron multicouche (MLP), précédés d'une

normalisation de couche (LN) et entourés de connexions résiduelles :

$$z'_l = \mathrm{MSA}\Big(\mathrm{LN}(z_{l-1})\Big) + z_{l-1} \tag{2.9}$$

$$z_l = \mathrm{MLP}\Big(\mathrm{LN}(z'_l)\Big) + z'_l \tag{2.10}$$

L'auto-attention calcule, pour chaque élément de la séquence, une somme pondérée des représentations de tous les éléments, les poids étant obtenus à partir de projections de requêtes Q, de clés K et de valeurs V de dimension d_k :

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V \tag{2.11}$$

Contrairement à la convolution, qui est locale, l'attention relie dès la première couche l'ensemble des patchs : le ViT possède moins de biais inductifs spatiaux qu'un CNN et nécessite en général davantage de données ou un pré-entraînement. Le tableau 2.1 compare les modèles évoqués.

TABLE 2.1 – Caractéristiques des architectures évoquées

Modèle	Type	Profondeur	Dimension	Paramètres (environ)
ResNet50	CNN résiduel	50 couches	2 048 (sortie)	25,6 M
ViT-B/16	Transformer	$L = 12$ blocs	$D = 768$	86 M
ViT-L/16 (RETFound)	Transformer	$L = 24$ blocs	$D = 1\,024$	307 M

2.4 RETFound et les modèles de fondation rétiniens

Un modèle de fondation est un modèle pré-entraîné à grande échelle, le plus souvent sans étiquettes, puis adapté à de nombreuses tâches. RETFound [22] est un modèle de fondation pour les images rétiniennes. Il repose sur un encodeur ViT-Large/16 pré-entraîné par apprentissage auto-supervisé de type auto-encodeur à masquage (MAE, [21]) sur environ 1,6 million d'images rétiniennes non étiquetées (photographies du fond d'œil et images OCT). Le principe consiste à masquer une forte proportion des patchs de l'image (de l'ordre de 75 %), à encoder les seuls patchs visibles, puis à reconstruire les patchs masqués avec un décodeur léger (figure 2.4). La perte est l'erreur quadratique moyenne sur les patchs masqués $\mathcal{M}$:

$$\mathcal{L}_{\mathrm{MAE}} = \frac{1}{|\mathcal{M}|} \sum_{i \in \mathcal{M}} \|x_i - \hat{x}_i\|^2 \tag{2.12}$$

Après ce pré-entraînement, le modèle est adapté (*fine-tuning*) à des tâches supervisées, telles que la détection de la rétinopathie diabétique ou du glaucome ; les auteurs rapportent de meilleures performances que celles de modèles pré-entraînés sur des images naturelles, en particulier lorsque les données annotées sont peu nombreuses [22].

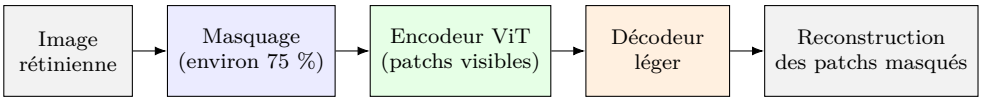


FIGURE 2.4 – Pré-entraînement auto-supervisé par auto-encodeur à masquage (MAE)

L'intérêt de RETFound pour ce travail est le pré-entraînement spécifique au domaine rétinien. **Dans les expériences rapportées ici, RETFound n'a pas été utilisé** : le modèle comparé à ResNet50 est un ViT-B/16 pré-entraîné sur ImageNet [18], de taille inférieure (tableau 2.1) et sans pré-entraînement rétinien. L'utilisation de RETFound, dans sa version ViT-Large pré-entraînée par MAE, est proposée comme perspective (chapitre 6).

2.5 Apprentissage par transfert

L'apprentissage par transfert consiste à réutiliser les connaissances acquises sur une tâche source (ici la classification d'ImageNet) pour résoudre une tâche cible disposant de peu de données annotées [23]. Les premières couches d'un réseau apprennent des caractéristiques générales (bords, textures) plus facilement transférables que celles des couches profondes, plus spécifiques à la tâche source [24]. Deux stratégies sont distinguées :

— l'**extraction de caractéristiques** : le réseau pré-entraîné est gelé et seule une nouvelle tête de classification est entraînée ; cette stratégie est peu coûteuse et limite le surapprentissage, mais l'adaptation au domaine cible est limitée ;

— le **fine-tuning** : tout ou partie des paramètres pré-entraînés est ré-entraîné avec un pas d'apprentissage faible ; l'adaptation est plus fine, mais le risque de surapprentissage est plus élevé lorsque les données sont rares.

Dans ce travail, ResNet50 est utilisé en extraction de caractéristiques (backbone entièrement gelé) et le ViT-B/16 en fine-tuning partiel (dernier bloc de l'encodeur et tête de classification).

2.6 Métriques d'évaluation

2.6.1 Matrice de confusion et métriques dérivées

Pour une classification binaire où la classe positive est le glaucome, la matrice de confusion dénombre les vrais positifs (VP), faux positifs (FP), vrais négatifs (VN) et

faux négatifs (FN). Les métriques suivantes en sont dérivées [25] :

$$\text{Exactitude} = \frac{VP + VN}{VP + VN + FP + FN} \tag{2.13}$$

$$\text{Précision} = \frac{VP}{VP + FP} \tag{2.14}$$

$$\text{Sensibilité (rappel)} = \frac{VP}{VP + FN} \tag{2.15}$$

$$\text{Spécificité} = \frac{VN}{VN + FP} \tag{2.16}$$

$$F_1 = \frac{2 \times \text{Précision} \times \text{Sensibilité}}{\text{Précision} + \text{Sensibilité}} \tag{2.17}$$

$$\text{VPN} = \frac{VN}{VN + FN} \tag{2.18}$$

$$\text{Exactitude équilibrée} = \frac{1}{2}\,(\text{Sensibilité} + \text{Spécificité}) \tag{2.19}$$

La **sensibilité** est la proportion de patients malades détectés : c'est la métrique prioritaire en dépistage, un faux négatif correspondant à un glaucome non détecté. La **spécificité** mesure la capacité à écarter les sujets sains et limite les fausses alertes. La **précision** est la proportion de vrais malades parmi les cas signalés. La **valeur prédictive négative** (VPN) indique dans quelle mesure une prédiction « sain » est fiable. L'**exactitude**, simple proportion de prédictions correctes, est trompeuse lorsque les classes sont déséquilibrées : un classifieur répondant toujours « glaucome » dans un jeu à 85 % de cas positifs atteint 0,85 d'exactitude. L'exactitude équilibrée et le score F_1 sont moins sensibles à ce déséquilibre.

2.6.2 Courbe ROC et AUC

Les modèles produisent une probabilité, convertie en classe par un seuil (0,5 dans ce travail). La courbe ROC représente la sensibilité en fonction de 1−spécificité lorsque le seuil varie [26]. L'aire sous cette courbe (AUC) mesure la capacité du modèle à discriminer les classes indépendamment du seuil ; elle est égale à la probabilité qu'un cas positif tiré au hasard reçoive un score supérieur à celui d'un cas négatif [27]. Une AUC de 0,5 correspond au hasard et une AUC de 1 à une séparation parfaite. En présence d'un fort déséquilibre, la courbe précision-rappel est plus informative que la courbe ROC [28].

2.6.3 Perte et suivi de l'entraînement

La perte (équation 2.4) est suivie sur l'entraînement et sur la validation. Une perte d'entraînement qui diminue alors que la perte de validation stagne ou augmente signale un surapprentissage. Contrairement aux métriques de classification, la perte est une grandeur continue et différentiable, sensible aux prédictions confiantes mais erronées.

2.6.4 Incertitude statistique des estimations

Les métriques sont estimées sur un jeu de test de taille finie et sont donc entachées d'une incertitude d'échantillonnage. L'intervalle de confiance à 95 % d'une proportion observée $\hat{p}$ sur n cas est calculé par la méthode de Wilson [29], qui reste valide pour les petites tailles d'échantillon et les proportions proches de 0 ou 1 :

$$\mathrm{IC}_{95\,\%} = \frac{\hat{p} + \dfrac{z^2}{2n} \pm z\sqrt{\dfrac{\hat{p}(1-\hat{p})}{n} + \dfrac{z^2}{4n^2}}}{1 + \dfrac{z^2}{n}}, \qquad z = 1{,}96 \tag{2.20}$$

Pour l'AUC, l'erreur standard approchée de Hanley et McNeil (1982) est utilisée, avec A l'AUC observée, n_P le nombre de cas positifs et n_N le nombre de cas négatifs :

$$SE = \sqrt{\frac{A(1-A) + (n_P - 1)(Q_1 - A^2) + (n_N - 1)(Q_2 - A^2)}{n_P\, n_N}}, \quad Q_1 = \frac{A}{2-A}, \quad Q_2 = \frac{2A^2}{1+A} \tag{2.21}$$

Cette estimation, qui suppose des scores binormaux, reste approximative ; lorsque la borne supérieure de l'intervalle dépasse 1, elle est ramenée à 1.

Chapitre 3

Datasets et méthodologie expérimentale

Ce chapitre décrit la démarche expérimentale commune aux deux jeux de données : démarche générale, présentation des deux datasets et de leur partition, prétraitement des images, modèles et paramètres d'entraînement, protocole d'évaluation et environnement logiciel. Les résultats propres à chaque dataset sont présentés aux chapitres 4 et 5.

3.1 Démarche expérimentale générale

L'étude croise trois facteurs : le jeu de données (ACRIMA, AI Glaucoma Dataset for AI Diagnosis), le modèle (ResNet50, ViT-B/16 pré-entraîné sur ImageNet [18]) et le pipeline d'images (images brutes, images prétraitées par CLAHE et recadrage). Elle comporte ainsi huit entraînements indépendants. Pour chaque jeu de données, la démarche est identique (figure 3.1) : étiquetage des images, partition en entraînement, validation et test, application du pipeline d'images, entraînement du modèle par transfert d'apprentissage, sélection du modèle sur la validation, puis évaluation unique sur le jeu de test.

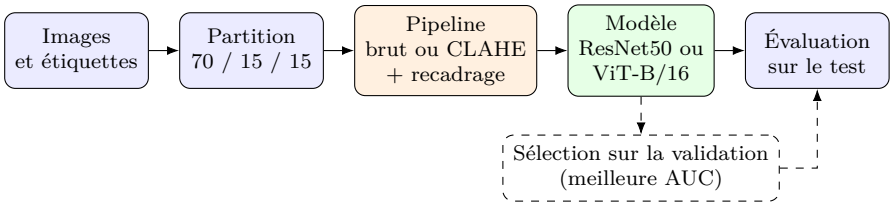


FIGURE 3.1 – Démarche expérimentale appliquée à chaque jeu de données

3.2 Jeux de données

3.2.1 ACRIMA

ACRIMA est une base publique d'images de fond d'œil pour l'évaluation du glaucome, présentée par Díaz-Pinto et al. (2019). Elle est utilisée ici dans la version distribuée sur Kaggle (identifiant `orvile/acrima-glaucoma-assessment-using-fundus-images`). Elle comporte 705 images, dont 396 glaucomateuses et 309 saines. Les images sont centrées sur la papille optique. L'étiquette est déduite du nom de fichier : tout fichier dont le nom contient `_g_` est étiqueté glaucome, les autres sont étiquetés sains. Les classes sont relativement équilibrées (56 % de glaucomes).

3.2.2 AI Glaucoma Dataset for AI Diagnosis

Le second jeu de données est distribué sur Kaggle (Bharathry, *Glaucoma Dataset for AI Diagnosis*). Il regroupe des images issues de trois bases publiques : G1020 [33], ORIGA-light [34] et REFUGE [35]. Il comporte 3 160 images, dont 2 678 étiquetées glaucome et 482 étiquetées saines. L'étiquette est déduite du nom du dossier de classe (`glaucoma` ou `normal`). Ce jeu est donc hétérogène par ses sources (appareils, résolutions, cadrages) et fortement déséquilibré (85 % de glaucomes). L'examen de la fiabilité de ses étiquettes est présenté à la section 5.5.

3.2.3 Partition des données

Pour chaque jeu, l'ensemble des images est réparti de manière stratifiée (la proportion de chaque classe est conservée) en 70 % pour l'entraînement, 15 % pour la validation et 15 % pour le test, avec une graine aléatoire fixée à 42. Les arborescences éventuelles du dataset (dossiers `train`, `val`, `test`) ne sont pas utilisées. Le découpage est réalisé au niveau de l'image, aucun identifiant patient n'étant disponible dans les données distribuées. La validation sert à sélectionner l'époque de l'entraînement ; le jeu de test n'intervient que pour l'évaluation finale.

3.3 Prétraitement des images

3.3.1 Pipeline sans prétraitement

L'image est lue en couleurs (RVB) puis redimensionnée à 224×224 pixels, taille d'entrée attendue par les deux modèles pré-entraînés.

3.3.2 Égalisation adaptative d'histogramme (CLAHE)

L'égalisation d'histogramme redistribue les niveaux d'intensité d'une image pour exploiter toute la dynamique disponible. Pour une image à L niveaux et une fonction

de répartition cumulée cdf des intensités, le niveau r_k est remplacé par :

$$s_k = \text{round}\Big((L-1)\,\text{cdf}(r_k)\Big) \tag{3.1}$$

Appliquée globalement, cette transformation peut sur-amplifier le bruit et les zones homogènes. L'égalisation adaptative [30] calcule la transformation sur des régions locales (tuiles), et sa variante à contraste limité, CLAHE [31], écrête l'histogramme de chaque tuile à une valeur maximale (limite de contraste) avant l'égalisation, puis interpole les résultats entre tuiles voisines pour éviter les discontinuités [32]. Dans ce travail, CLAHE est appliquée au canal de luminance L de l'espace colorimétrique LAB, ce qui rehausse le contraste local sans altérer la teinte, avec une limite de contraste de 2,0 et une grille de 8×8 tuiles.

3.3.3 Recadrage et normalisation

Après CLAHE, un recadrage central conserve 90 % de la hauteur et de la largeur de l'image, ce qui réduit la part du fond sans information, puis l'image est redimensionnée à 224×224 pixels. Les valeurs de pixels sont ensuite normalisées selon la convention du modèle : la fonction de pré-traitement de Keras pour ResNet50 et la moyenne et l'écart-type d'ImageNet pour le ViT-B/16.

3.4 Modèles et protocole d'entraînement

Le **ResNet50** est utilisé en extraction de caractéristiques : le backbone pré-entraîné sur ImageNet [18] est entièrement gelé, et une tête de classification est entraînée (moyennage global spatial, *dropout* à 0,3, couche dense de 128 neurones avec ReLU, *dropout* à 0,3, sortie sigmoïde). Le **ViT-B/16** pré-entraîné sur ImageNet [18], chargé depuis la bibliothèque `timm` [40], est adapté par *fine-tuning* partiel : le dernier bloc de l'encodeur et la couche linéaire de classification (une sortie) sont entraînés, les autres paramètres étant gelés. Le tableau 3.1 récapitule la configuration des deux entraînements.

Les deux pipelines diffèrent par plus que l'architecture : profondeur de l'adaptation (backbone gelé contre dernier bloc dégelé), optimiseur, bibliothèque et nombre maximal d'époques. La comparaison porte donc sur deux pipelines complets de transfert d'apprentissage, et non sur les seules architectures. Dans les deux cas, les poids retenus sont ceux de l'époque présentant la meilleure AUC sur la validation, et non ceux de la dernière époque.

3.5 Protocole d'évaluation

Chaque configuration est évaluée une seule fois sur le jeu de test, au seuil de 0,5. Les résultats sont présentés par la matrice de confusion, la courbe ROC et les métriques définies au chapitre 2 (exactitude, sensibilité, spécificité, précision, F1, AUC, valeur prédictive négative, exactitude équilibrée). Les intervalles de confiance sont calculés par

TABLE 3.1 – Configuration d'entraînement des deux modèles

	ResNet50	**ViT-B/16 (ImageNet)**
Bibliothèque	TensorFlow / Keras	PyTorch / `timm`
Poids initiaux	ImageNet	ImageNet
Paramètres entraînés	Tête de classification seule	Dernier bloc encodeur + couche linéaire
Tête	Moyennage global, *dropout* (0,3), dense 128 (ReLU), *dropout* (0,3), sigmoïde	Couche linéaire à 1 sortie
Fonction de perte	Entropie croisée binaire	Entropie croisée binaire (logits)
Pondération des classes	Poids $N/(2N_c)$	`pos_weight` $= N_0/N_1$
Optimiseur	Adam [13], pas 10^{-4}	AdamW [14], pas 10^{-4}, décroissance des poids 10^{-2}
Taille de lot	16 (ACRIMA), 32 (second dataset)	16 (ACRIMA), 32 (second dataset)
Époques maximales	20	15
Sélection du modèle	Meilleure AUC de validation, arrêt anticipé (patience 5)	Meilleure AUC de validation
Augmentation de données	Aucune	Aucune
Seuil de décision	0,5	0,5

les méthodes de Wilson et de Hanley et McNeil (équations 2.20 et 2.21). Les courbes d'apprentissage (perte, exactitude, AUC de validation) complètent l'analyse du comportement des modèles.

3.6 Environnement logiciel et reproductibilité

Les entraînements ont été réalisés dans des carnets Jupyter exécutés sur la plateforme Google Colaboratory avec un processeur graphique. Les modèles ResNet50 sont implémentés avec TensorFlow et Keras [36], les ViT-B/16 avec PyTorch [37] et la bibliothèque `timm`. Le traitement d'images utilise OpenCV [38] et les métriques sont calculées avec scikit-learn [39]. Les jeux de données sont téléchargés depuis Kaggle. La graine aléatoire est fixée à 42 pour la partition ; aucune répétition avec d'autres graines n'a été réalisée.

3.7 Limites méthodologiques

Plusieurs limites, discutées aux chapitres 4 à 6, sont inhérentes au protocole : partition au niveau de l'image, absence de répétition des entraînements, jeux de test de taille limitée, pipelines des deux modèles non strictement comparables, absence de pré-entraînement rétinien pour le ViT-B/16, seuil de décision fixe et étiquettes non vérifiées par un expert dans le cadre du stage.

Chapitre 4

Résultats expérimentaux sur ACRIMA

Ce chapitre présente les résultats obtenus par ResNet50 et par le ViT-B/16 pré-entraîné sur ImageNet [18] sur le dataset ACRIMA. La configuration propre à ce dataset est d'abord décrite. Les résultats de chaque modèle sont ensuite analysés séparément, puis comparés. Une démonstration qualitative sur une image externe acquise au Centre Hospitalier Ibn Sina est ensuite présentée, avant les limites propres à ce dataset et une conclusion partielle, indépendante de celle du chapitre 5.

4.1 Configuration expérimentale sur ACRIMA

4.1.1 Composition du dataset et partition des données

Le dataset ACRIMA comporte 705 images (396 glaucomes, 309 sains). Selon la partition décrite au chapitre 3, 493 images servent à l'entraînement, 106 à la validation et 106 au test. Le tableau 4.1 donne les effectifs. Contrairement au second dataset, les classes sont relativement équilibrées (56 % de glaucomes) : le niveau de référence d'un classifieur prédisant toujours la classe majoritaire est de $59/106 \approx 0{,}557$ d'exactitude sur le jeu de test. Le jeu de test ne contient que 47 images saines et 59 images glaucomateuses ; l'écart d'une image représente donc près d'un point d'exactitude, ce qui impose la prudence dans l'interprétation des différences.

Table 4.1 – Effectifs d'ACRIMA et partition utilisée

Ensemble	Sains	Glaucomes	Total	Part de glaucomes
Entraînement*	216	277	493	56,2 %
Validation*	46	60	106	56,6 %
Test	47	59	106	55,7 %
Total	309	396	705	56,2 %

* Effectifs déduits des effectifs totaux, de l'effectif de test et du principe de stratification.

4.1.2 Prétraitement des images

Le prétraitement (CLAHE sur le canal de luminance, recadrage central à 90 %, redimensionnement à 224×224) est décrit au chapitre 3. La figure 4.1 illustre son effet sur une image ACRIMA. Les images de ce dataset sont déjà centrées sur la papille : le recadrage retire seulement une marge périphérique et l'effet principal est celui de CLAHE, qui accentue le contraste local des vaisseaux et du bord de la papille. Comme sur le second dataset, un grain accentué est visible après traitement, effet attendu de l'égalisation locale d'histogramme.



FIGURE 4.1 – Image ACRIMA avant (à gauche) et après (à droite) prétraitement par CLAHE et recadrage

4.1.3 Paramètres d'entraînement

La configuration des entraînements est donnée au tableau 3.1 (chapitre 3). Sur ACRIMA, la taille de lot est de 16. Les poids de classes du ResNet50 et le coefficient `pos_weight` du ViT-B/16 sont calculés à partir des effectifs d'entraînement du dataset.

4.2 Résultats du ResNet50

4.2.1 Courbes d'apprentissage

Les figures 4.2 et 4.3 présentent l'évolution de la perte et de l'exactitude du ResNet50 sans, puis avec prétraitement. Sans prétraitement, l'arrêt anticipé interrompt l'entraînement après 18 époques ; la meilleure AUC de validation (0,9877) est atteinte à l'époque 13. Avec prétraitement, les 20 époques autorisées sont réalisées et la meilleure AUC de validation (0,9964) est atteinte à l'époque 17.

Dans les deux cas, la perte d'entraînement décroît régulièrement (de 0,81 à 0,21 sans prétraitement, à 0,16 avec) et la perte de validation décroît de 0,47 à environ 0,19 sans prétraitement et à environ 0,11 avec prétraitement. La perte de validation reste inférieure à la perte d'entraînement : cet écart s'explique par la pondération des classes et le *dropout* actif à l'entraînement, et ne traduit pas une anomalie. L'exactitude de

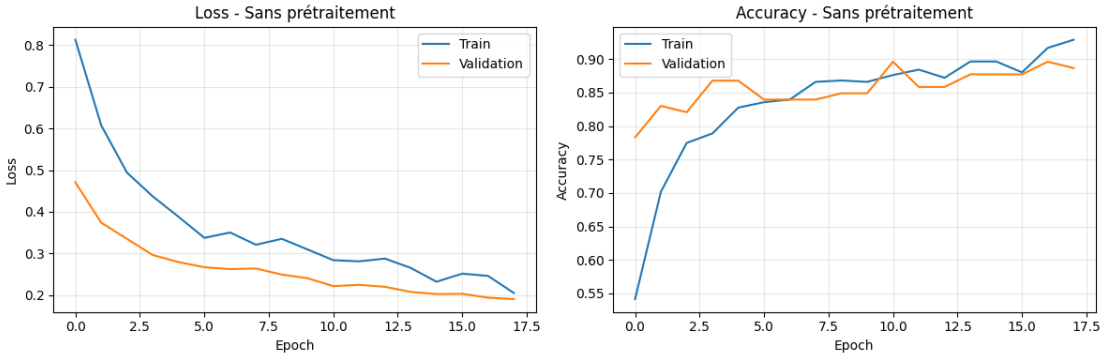


FIGURE 4.2 – Courbes d'apprentissage du ResNet50 sans prétraitement sur ACRIMA

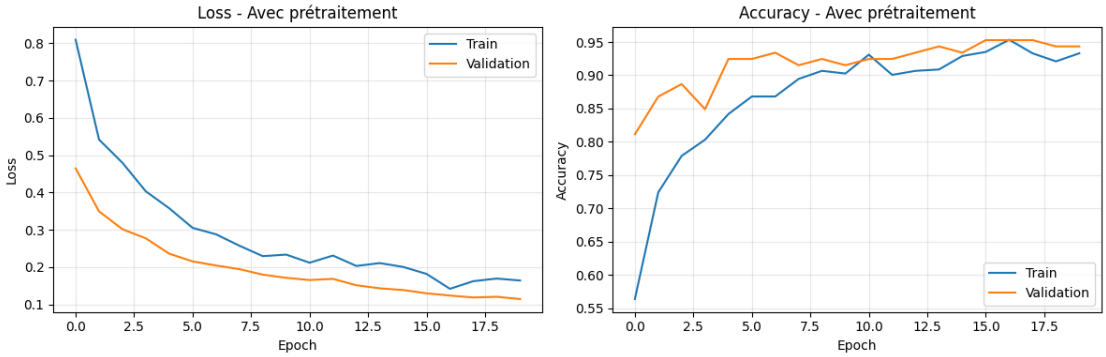


FIGURE 4.3 – Courbes d'apprentissage du ResNet50 avec prétraitement sur ACRIMA

validation est nettement plus élevée avec prétraitement (environ 0,94-0,95 en fin d'entraînement, contre 0,86-0,89 sans prétraitement), ce qui annonce l'écart observé sur le jeu de test. Aucune divergence entre entraînement et validation n'est observée : le backbone étant gelé, la capacité d'adaptation du modèle est limitée.

4.2.2 Performances sur le jeu de test

La figure 4.4 présente les matrices de confusion sur les 106 images de test. Sans prétraitement, le modèle classe à tort 6 images saines comme glaucomateuses (41 vrais négatifs) et 2 images glaucomateuses comme saines (57 vrais positifs). Avec prétraitement, il ne commet plus qu'un faux positif (46 vrais négatifs) et un faux négatif (58 vrais positifs).

Le tableau 4.2 et la figure 4.5 présentent les métriques et les courbes ROC. L'exactitude passe de 0,9245 à 0,9811 (six images supplémentaires correctement classées), la sensibilité de 0,9661 à 0,9831, la spécificité de 0,8723 à 0,9787 et le score F1 de 0,9344 à 0,9831. L'AUC passe de 0,9906 à 0,9960. L'amélioration porte donc surtout sur la spécificité : sans prétraitement, le modèle tend à signaler à tort des sujets sains. Une interprétation possible, non vérifiée ici, est que le rehaussement du contraste local rend plus discriminante la frontière entre l'excavation et l'anneau neurorétinien.

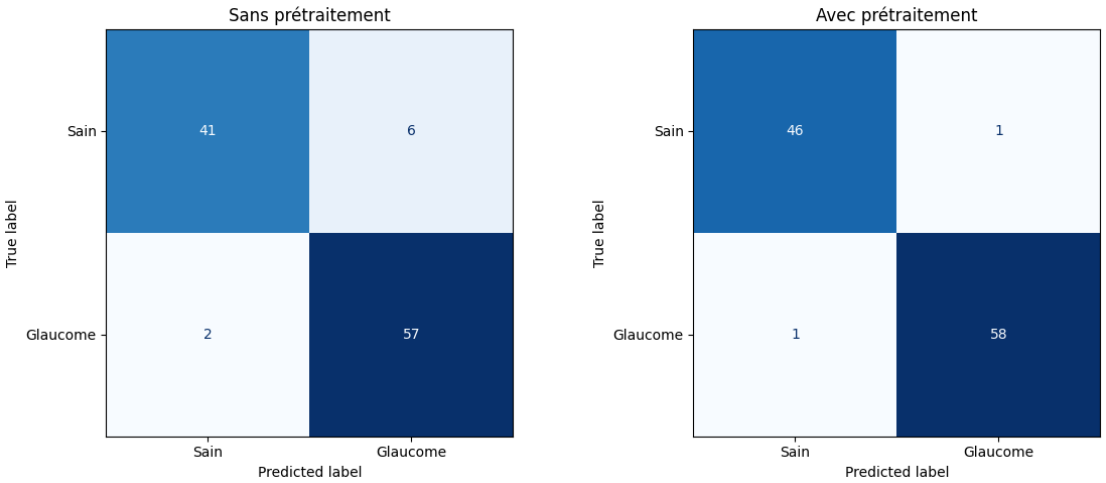


FIGURE 4.4 – Matrices de confusion du ResNet50 sur le jeu de test d'ACRIMA, sans et avec prétraitement

TABLE 4.2 – Métriques de test du ResNet50 sur ACRIMA

Pipeline	Exactitude	Sensibilité	Spécificité	Précision	F1	AUC
Sans prétraitement	0,9245	0,9661	0,8723	0,9048	0,9344	0,9906
Avec prétraitement	0,9811	0,9831	0,9787	0,9831	0,9831	0,9960

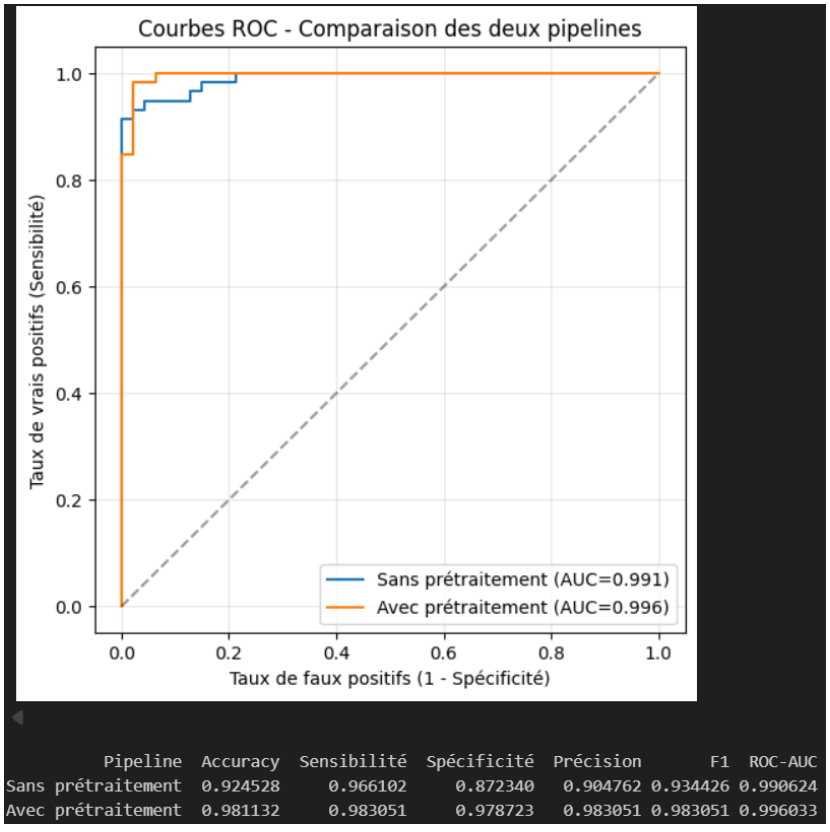


FIGURE 4.5 – Courbes ROC du ResNet50 sur le jeu de test d'ACRIMA, sans et avec prétraitement

4.3 Résultats du ViT-B/16 pré-entraîné sur ImageNet [18]

4.3.1 Courbes d'apprentissage

La figure 4.6 présente la perte, l'exactitude et l'AUC de validation du ViT-B/16 au cours des 15 époques, sans et avec prétraitement. L'axe de l'exactitude est libellé « Précision (%) » dans la figure d'origine ; il s'agit de l'exactitude (*accuracy*).

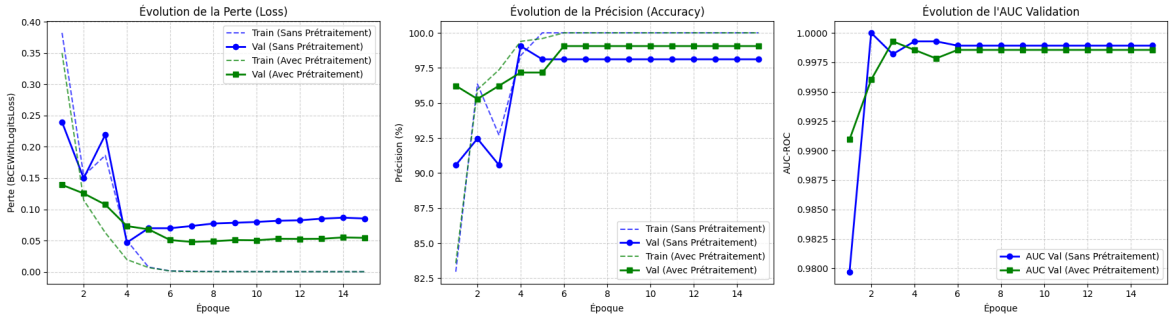


FIGURE 4.6 – Courbes d'apprentissage du ViT-B/16 sur ACRIMA : perte, exactitude et AUC de validation

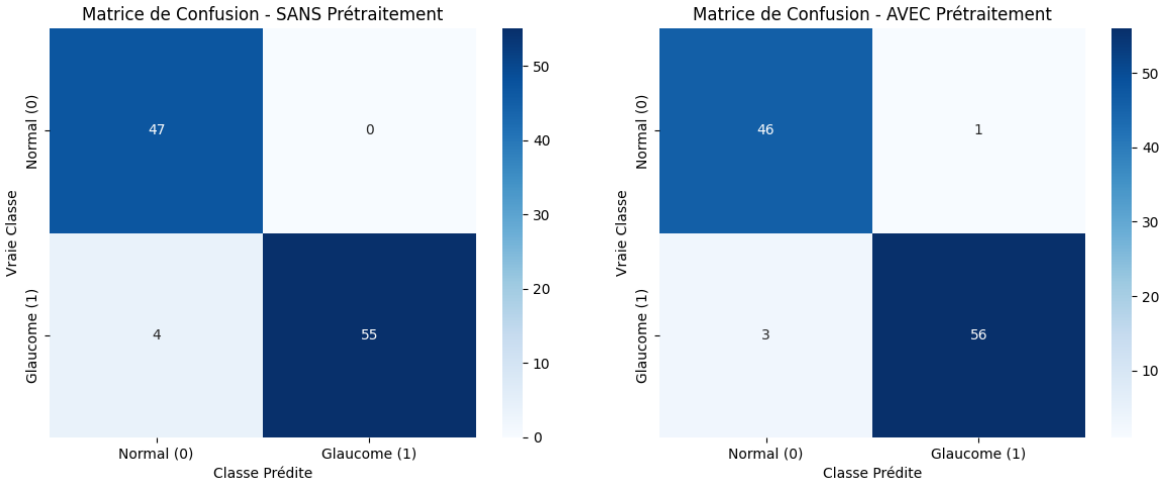
L'apprentissage est très rapide. L'exactitude d'entraînement atteint 100 % dès l'époque 5 ou 6 et la perte d'entraînement tend vers zéro (de l'ordre de 10^{-4} à la dernière époque), signe d'une mémorisation du jeu d'entraînement, peu volumineux (493 images) au regard de la capacité du dernier bloc dégelé. La perte de validation sans prétraitement passe par un minimum d'environ 0,05 à l'époque 4, puis remonte lentement jusqu'à environ 0,085 ; avec prétraitement, elle se stabilise autour de 0,05. L'AUC de validation est très élevée dès les premières époques (supérieure à 0,97) et sature : la meilleure AUC est de 1,0000 à l'époque 2 sans prétraitement et de 0,9993 à l'époque 3 avec prétraitement.

Les poids retenus pour l'évaluation sont donc ceux de ces époques précoces. À ces époques, l'exactitude de validation est de 92,45 % (sans prétraitement) et de 96,23 % (avec prétraitement), inférieure aux 98-99 % atteints en fin d'entraînement. L'AUC de validation, qui évalue le classement des scores indépendamment du seuil, étant saturée, elle discrimine mal les époques : le critère de sélection retient une époque dont le comportement au seuil de 0,5 n'est pas le meilleur de l'entraînement. Ce point est discuté aux limites (section 4.6).

4.3.2 Performances sur le jeu de test

Les matrices de confusion du ViT-B/16 sont présentées dans la figure 4.11. Sans prétraitement, aucune image saine n'est classée à tort (47 vrais négatifs) mais 4 images glaucomateuses sont manquées (55 vrais positifs). Avec prétraitement, un faux positif apparaît (46 vrais négatifs) et 3 faux négatifs subsistent (56 vrais positifs).

Le tableau 4.3 et la figure 4.8 présentent les métriques et les courbes ROC. L'exactitude est identique dans les deux pipelines (0,9623, soit 102 images sur 106). Le



(a) Sans prétraitement (b) Avec prétraitement

FIGURE 4.7 – Matrices de confusion du ViT-B/16 sur le jeu de test d'ACRIMA

prétraitement déplace en revanche le compromis entre sensibilité et spécificité : la sensibilité passe de 0,9322 à 0,9492 (un vrai positif de plus), la spécificité de 1,0000 à 0,9787 (un faux positif de plus). L'AUC passe de 0,9910 à 0,9982, la plus élevée des quatre configurations d'ACRIMA.

TABLE 4.3 – Métriques de test du ViT-B/16 sur ACRIMA

Pipeline	Exactitude	Sensibilité	Spécificité	Précision	F1	AUC
Sans prétraitement	0,9623	0,9322	1,0000	1,0000	0,9649	0,9910
Avec prétraitement	0,9623	0,9492	0,9787	0,9825	0,9655	0,9982

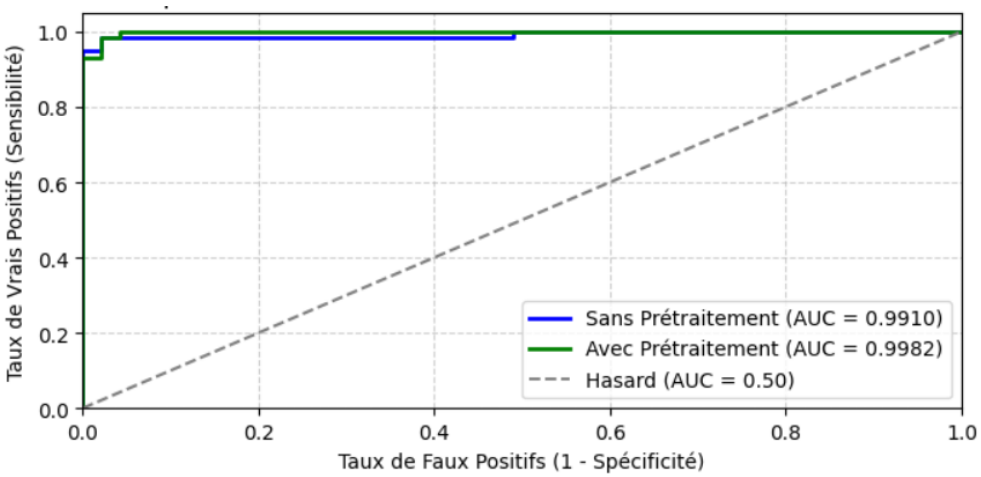


FIGURE 4.8 – Courbes ROC du ViT-B/16 sur le jeu de test d'ACRIMA, sans et avec prétraitement

4.4 Comparaison des deux modèles sur ACRIMA

4.4.1 Synthèse des métriques

Le tableau 4.4 réunit les quatre configurations. L'exactitude équilibrée (équation 2.19) et la valeur prédictive négative (équation 2.18), définies au chapitre 2, y sont ajoutées.

TABLE 4.4 – Synthèse des performances de test sur ACRIMA

Configuration	Exact.	Sensib.	Spécif.	Préc.	VPN	F1	Exact. équil.	AUC
ResNet50, sans prétr.	0,9245	0,9661	0,8723	0,9048	0,9535	0,9344	0,9192	0,9906
ResNet50, avec prétr.	0,9811	0,9831	0,9787	0,9831	0,9787	0,9831	0,9809	0,9960
ViT-B/16, sans prétr.	0,9623	0,9322	1,0000	1,0000	0,9216	0,9649	0,9661	0,9910
ViT-B/16, avec prétr.	0,9623	0,9492	0,9787	0,9825	0,9388	0,9655	0,9639	0,9982

4.4.2 Analyse métrique par métrique

Exactitude. Elle varie de 0,9245 à 0,9811 (98 à 104 images correctes sur 106), pour un niveau de référence de 0,557. Le meilleur résultat est celui du ResNet50 avec prétraitement, qui dépasse de deux images les deux configurations du ViT-B/16 (102 images) et de six images le ResNet50 sans prétraitement.

Sensibilité. Le ResNet50 avec prétraitement ne manque qu'un cas de glaucome (0,9831), le ResNet50 sans prétraitement en manque deux (0,9661), le ViT-B/16 en manque trois à quatre (0,9492 et 0,9322). Dans une perspective de dépistage, le ResNet50 avec prétraitement est donc la configuration la plus favorable sur cette métrique, mais l'écart avec les autres représente un à trois patients sur 59.

Spécificité et précision. Le ViT-B/16 sans prétraitement ne produit aucune fausse alerte (spécificité et précision de 1,0000), alors que le ResNet50 sans prétraitement en produit six (spécificité de 0,8723, précision de 0,9048), ce qui en fait la configuration la plus faible sur ces deux métriques.

Score F1. Il suit l'exactitude : 0,9831 pour le ResNet50 avec prétraitement, 0,9649 et 0,9655 pour le ViT-B/16, 0,9344 pour le ResNet50 sans prétraitement.

AUC. Le classement par AUC diffère du classement par exactitude : le ViT-B/16 avec prétraitement obtient la meilleure AUC (0,9982), devant le ResNet50 avec prétraitement (0,9960), puis les deux configurations sans prétraitement (0,9906 et 0,9910). Le ViT-B/16 classe donc très bien les scores, mais le seuil de 0,5 n'est pas celui qui maximise ses performances de classification ; le ResNet50 avec prétraitement est mieux calibré par rapport à ce seuil.

Exactitude équilibrée et VPN. L'exactitude équilibrée confirme l'avantage du ResNet50 avec prétraitement (0,9809). La VPN est la plus faible pour le ViT-B/16 sans prétraitement (0,9216) : sur les 51 images déclarées saines, 4 sont glaucomateuses.

4.4.3 Incertitude statistique

Le tableau 4.5 donne les intervalles de confiance à 95 % (équations 2.20 et 2.21). Avec 106 images de test, les intervalles sont larges : la demi-largeur de l'intervalle d'exactitude est de l'ordre de 4 à 5 points.

TABLE 4.5 – Intervalles de confiance à 95 % des métriques de test (ACRIMA)

Configuration	Exactitude	Sensibilité	Spécificité	AUC
ResNet50, sans prétr.	0,925 [0,858 ; 0,961]	0,966 [0,885 ; 0,991]	0,872 [0,748 ; 0,940]	0,991 [0,973 ; 1,000]
ResNet50, avec prétr.	0,981 [0,934 ; 0,995]	0,983 [0,910 ; 0,997]	0,979 [0,889 ; 0,996]	0,996 [0,985 ; 1,000]
ViT-B/16, sans prétr.	0,962 [0,907 ; 0,985]	0,932 [0,838 ; 0,973]	1,000 [0,924 ; 1,000]	0,991 [0,974 ; 1,000]
ViT-B/16, avec prétr.	0,962 [0,907 ; 0,985]	0,949 [0,861 ; 0,983]	0,979 [0,889 ; 0,996]	0,998 [0,990 ; 1,000]

Les intervalles se recouvrent pour la plupart des comparaisons. Le seul écart proche d'une séparation est celui de l'exactitude du ResNet50 sans prétraitement ([0,858 ; 0,961]) et avec prétraitement ([0,934 ; 0,995]), dont les intervalles ne se recouvrent que sur 2,7 points. Cet écart est cohérent avec la différence observée sur les courbes de validation et avec l'ensemble des métriques, ce qui en fait l'indice le plus net d'un effet du prétraitement dans cette étude. Il ne constitue pas pour autant une preuve : les intervalles ne tiennent pas compte de l'appariement des prédictions, ni de la variabilité due à l'initialisation, aucune répétition n'ayant été réalisée.

4.5 Démonstration qualitative de prédictions individuelles

4.5.1 Dispositif d'acquisition

Pour illustrer le fonctionnement des modèles hors des jeux de données publics, les modèles entraînés sur ACRIMA ont été appliqués à une image externe de fond d'œil acquise au Centre Hospitalier Ibn Sina. L'image a été obtenue avec un rétinographe de marque Canon (figure 4.9) et est visualisée sur le poste d'acquisition associé (figure 4.10). Le dispositif d'acquisition, les conditions d'éclairage, la résolution et le cadrage diffèrent de ceux des images d'ACRIMA : cet exemple est donc hors de la distribution des données d'entraînement.

4.5.2 Prédictions des deux modèles

La figure **??** présente l'image testée, brute puis prétraitée par CLAHE et recadrage. L'état sain du sujet n'a pas fait l'objet d'une validation clinique formelle dans le cadre de ce travail ; l'exemple est présenté à titre illustratif et ne constitue pas une validation.



FIGURE 4.9 – Rétinographe Canon utilisé pour l'acquisition des images du fond d'œil (arrière-plan partiellement flouté)

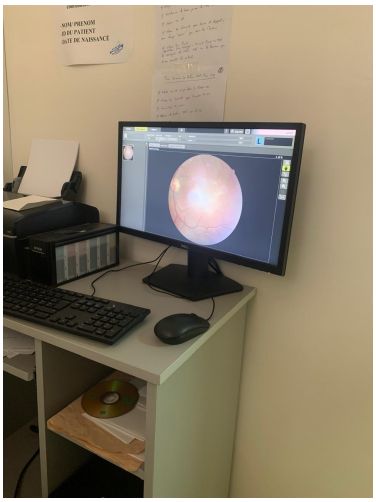
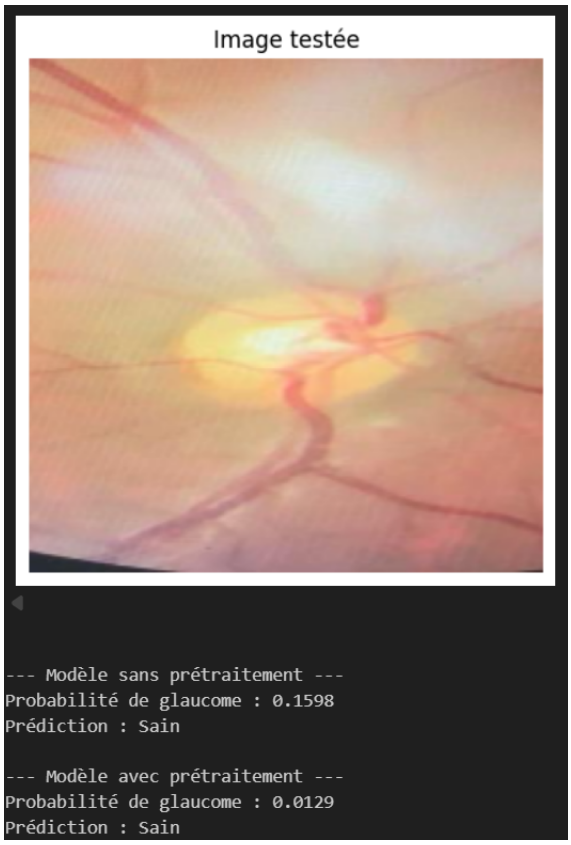
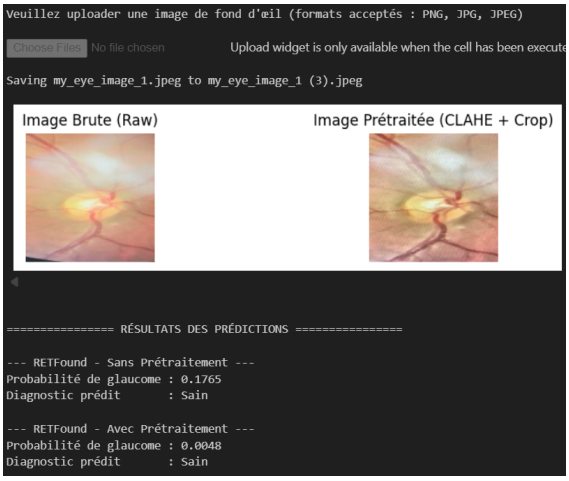


FIGURE 4.10 – Poste d'acquisition affichant une image du fond d'œil

Le tableau 4.6 donne les probabilités de glaucome produites par les deux modèles, un seuil de 0,5 étant appliqué pour la décision.



(a) Resultat pour ResNet50



(b) Resultat pour ViT-B/16

FIGURE 4.11 – Image externe testée et résultats de prédiction sur ACRIMA

TABLE 4.6 – Probabilités de glaucome sur l'image externe testée

Modèle	Sans prétraitement		Avec prétraitement	
	Probabilité	Prédiction	Probabilité	Prédiction
ResNet50	0,1598	Sain	0,0129	Sain
ViT-B/16	0,1765	Sain	0,0048	Sain

Les deux modèles prédisent « sain » dans les deux pipelines. Les probabilités de glaucome sont voisines sans prétraitement (0,1598 pour le ResNet50 et 0,1765 pour le ViT-B/16). Avec prétraitement, elles diminuent nettement pour les deux modèles (0,0129 et 0,0048), le ViT-B/16 étant le plus confiant. Cette cohérence entre les deux modèles est compatible avec leurs performances sur le jeu de test d'ACRIMA : avec prétraitement, la spécificité est de 0,9787 pour les deux, et la prédiction « sain » sur un sujet considéré comme sain est le comportement attendu.

Ces résultats doivent être interprétés avec prudence. Une seule image ne permet de calculer ni sensibilité ni spécificité, et une probabilité faible n'est pas une preuve de fiabilité diagnostique : les probabilités produites par un réseau ne sont pas

nécessairement calibrées, et l'image est hors de la distribution d'entraînement. L'augmentation de la confiance après prétraitement ne prouve pas une meilleure exactitude, une confiance élevée pouvant aussi accompagner une erreur. L'exemple illustre le fonctionnement du pipeline de bout en bout sur une image réelle d'un autre dispositif, sans valeur de validation clinique.

4.6 Limites propres à ACRIMA

— **Jeu de test de petite taille.** Avec 106 images dont 47 saines, une image d'écart représente près d'un point d'exactitude et les intervalles de confiance sont larges (tableau 4.5).

— **Une seule exécution par configuration.** La variabilité liée à l'initialisation n'est pas mesurée ; les écarts de quelques images ne sont pas interprétables comme des différences établies.

— **Saturation des métriques de classement.** Les AUC proches de 1 (0,991 à 0,998) limitent le pouvoir discriminant de la comparaison, et l'AUC de validation de 1,0000 atteinte par le ViT-B/16 rend le critère de sélection de l'époque peu informatif.

— **Critère de sélection et seuil.** Le modèle est sélectionné sur l'AUC de validation, mais évalué au seuil de 0,5 ; l'époque retenue peut ne pas être la plus performante à ce seuil, comme le montre l'écart entre l'exactitude de validation à l'époque retenue et en fin d'entraînement pour le ViT-B/16.

— **Dataset mono-source et découpage par image.** ACRIMA est une base issue d'un contexte d'acquisition unique ; les performances n'indiquent pas la capacité à fonctionner sur des images d'un autre appareil, ce que l'exemple qualitatif illustre sans le mesurer.

— **Étiquettes non revérifiées.** Les étiquettes sont celles fournies avec la base (déduites du nom de fichier) et n'ont pas été revues par un expert dans le cadre du stage.

4.7 Conclusion partielle

Sur ACRIMA, les performances sont élevées pour les quatre configurations : exactitude de 0,925 à 0,981, sensibilité de 0,932 à 0,983 et AUC de 0,991 à 0,998.

Meilleur modèle. Au seuil de 0,5, la meilleure configuration est le ResNet50 avec prétraitement (exactitude 0,9811, sensibilité 0,9831, spécificité 0,9787, F1 0,9831). Au regard de l'AUC, la meilleure configuration est le ViT-B/16 avec prétraitement (0,9982). Les intervalles de confiance se recouvrent, hormis un écart proche d'une séparation entre les deux pipelines du ResNet50.

Effet du prétraitement. Il est net pour le ResNet50 (six images de plus correctement classées, spécificité de 0,8723 à 0,9787, AUC de 0,9906 à 0,9960) et cohérent avec les courbes de validation. Pour le ViT-B/16, l'exactitude ne change pas (102 images sur

106) : le prétraitement modifie le compromis entre sensibilité (+1 vrai positif) et spécificité (+1 faux positif) et accroît l'AUC (0,9910 à 0,9982).

Comportement des architectures. Le ResNet50, dont le backbone est gelé, présente un apprentissage stable. Le ViT-B/16 apprend très rapidement et mémorise l'ensemble d'entraînement (exactitude d'entraînement de 100 %) ; la sélection sur l'AUC de validation limite l'impact de ce surapprentissage mais retient des époques précoces.

Portée. Ces conclusions concernent un dataset mono-source de petite taille et un jeu de test de 106 images : elles sont indicatives. L'exemple qualitatif sur une image externe (deux prédictions « sain ») illustre le fonctionnement des modèles mais n'a pas valeur de validation. La comparaison avec le second dataset est traitée au chapitre 6.

Chapitre 5

Résultats expérimentaux sur le second dataset

*Ce chapitre présente les résultats obtenus par ResNet50 et par un Vision Transformer ViT-B/16 pré-entraîné sur ImageNet [18] sur le second jeu de données, l'*AI Glaucoma Dataset for AI Diagnosis*, qui regroupe des images issues des bases G1020, ORIGA et REFUGE. La configuration expérimentale propre à ce dataset est d'abord décrite. Les résultats de chaque modèle (courbes d'apprentissage, matrices de confusion, courbes ROC et métriques) sont ensuite analysés séparément, puis comparés. Une section est consacrée à la fiabilité des étiquettes du dataset : l'examen de la structure des dossiers laisse envisager une limite potentielle (doublons, images saines étiquetées « glaucome »), dont la procédure de vérification et de correction est détaillée. Le chapitre s'achève par une conclusion partielle, indépendante de celle du chapitre 4.*

5.1 Configuration expérimentale sur le second dataset

5.1.1 Composition du dataset et partition des données

Le dataset est distribué sur Kaggle (Bharathry, *Glaucoma Dataset for AI Diagnosis*) et rassemble des images de fond d'œil provenant de trois bases publiques : G1020 [33], ORIGA-light [34] et REFUGE [35]. Il est livré avec une arborescence `train`, `val` et `test`. Dans le protocole suivi, cette arborescence n'est pas utilisée comme partition : l'ensemble des 3 160 images est regroupé, étiqueté d'après le nom du dossier de classe (`glaucoma` → 1, `normal` → 0), puis réparti de manière stratifiée en 70 % pour l'entraînement, 15 % pour la validation et 15 % pour le test, avec une graine aléatoire fixée à 42. Le découpage est réalisé au niveau de l'image et non du patient, aucun identifiant patient n'étant disponible dans le dataset.

Le tableau 5.1 donne les effectifs obtenus. La classe « glaucome » représente environ 85 % des images, ce déséquilibre étant conservé dans les trois sous-ensembles. Deux

conséquences méthodologiques en découlent. D'une part, un classifieur qui prédirait systématiquement « glaucome » atteindrait sur le jeu de test une exactitude de $401/474 \approx 0{,}846$: l'exactitude doit donc être lue par rapport à ce niveau de référence, et complétée par la sensibilité, la spécificité, le score F1 et l'AUC. D'autre part, le jeu de test ne contient que 73 images saines, ce qui rend les estimations de spécificité peu précises.

TABLE 5.1 – Effectifs du second dataset et partition utilisée

Ensemble	Sains	Glaucomes	Total	Part de glaucomes
Entraînement	337	1 875	2 212	84,8 %
Validation*	72	402	474	84,8 %
Test	73	401	474	84,6 %
Total	482	2 678	3 160	84,7 %

* Effectifs de validation déduits par différence avec les effectifs totaux, d'entraînement et de test.

5.1.2 Prétraitement des images

Le prétraitement est identique à celui appliqué sur le premier dataset (chapitre 3). L'image est convertie dans l'espace colorimétrique LAB, puis l'égalisation adaptative d'histogramme à contraste limité (CLAHE, Zuiderveld, 1994) est appliquée sur le canal de luminance avec une limite de contraste de 2,0 et une grille de 8×8 tuiles. L'image est ensuite recadrée au centre (90 % de la hauteur et de la largeur), puis redimensionnée à 224×224 pixels. Dans le pipeline sans prétraitement, l'image est seulement redimensionnée.

La figure 5.1 illustre l'effet de ce traitement sur une image du dataset. Le contraste local des vaisseaux et des bords de la papille est renforcé ; le recadrage réduit la part du fond noir entourant la rétine ; le grain de l'image apparaît également accentué, effet attendu de l'égalisation locale d'histogramme, qui amplifie aussi le bruit.

5.1.3 Modèles et paramètres d'entraînement

Deux architectures sont comparées. Le **ResNet50** [17] est utilisé comme extracteur de caractéristiques : le backbone pré-entraîné sur ImageNet [18] est entièrement gelé, et seule une tête de classification est entraînée. Le **ViT-B/16** est adapté par *fine-tuning* partiel (dernier bloc et tête linéaire). La taille de lot est de 32 sur ce second dataset.

5.2 Résultats du ResNet50

5.2.1 Courbes d'apprentissage

Les figures 5.2 et 5.3 présentent l'évolution de la perte et de l'exactitude du ResNet50 sans et avec prétraitement sur le second dataset. L'apprentissage se stabilise

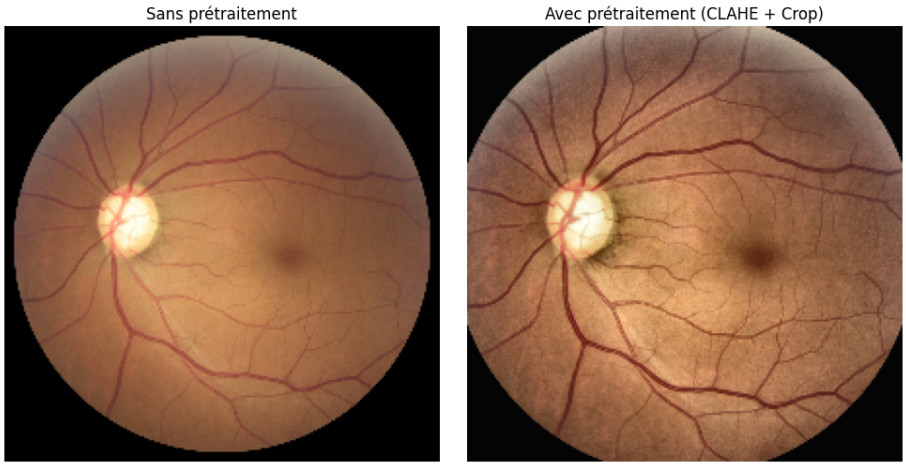


FIGURE 5.1 – Image du second dataset avant (à gauche) et après (à droite) prétraitement par CLAHE et recadrage

rapidement autour de 15 à 20 époques avec une perte d'entraînement qui diminue régulièrement sous la barre des 0,12.

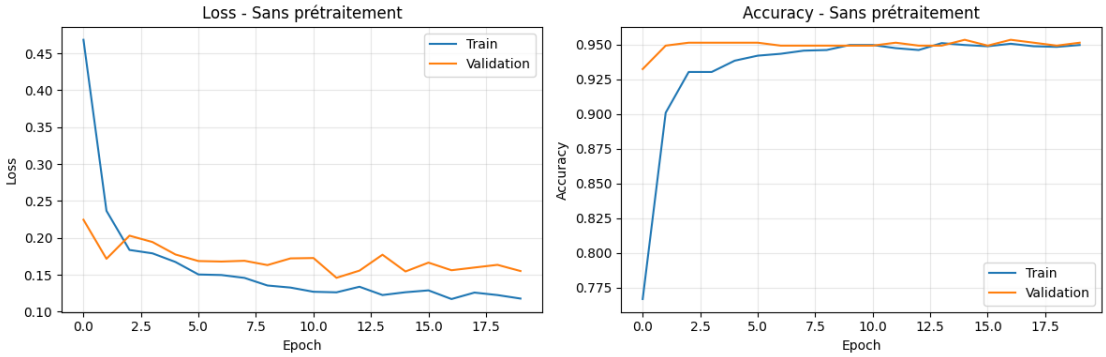


FIGURE 5.2 – Courbes d'apprentissage du ResNet50 sans prétraitement sur le second dataset

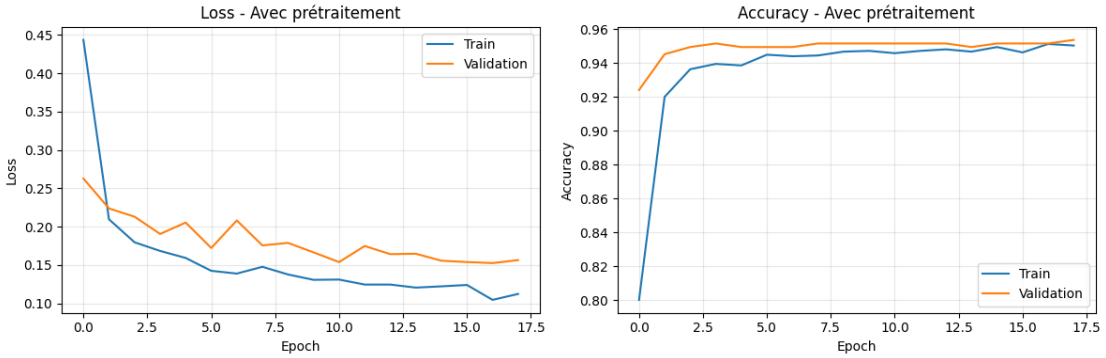


FIGURE 5.3 – Courbes d'apprentissage du ResNet50 avec prétraitement sur le second dataset

5.2.2 Performances sur le jeu de test

La figure 5.4 présente les matrices de confusion obtenues par le ResNet50 sans et avec prétraitement sur les 474 images du jeu de test.

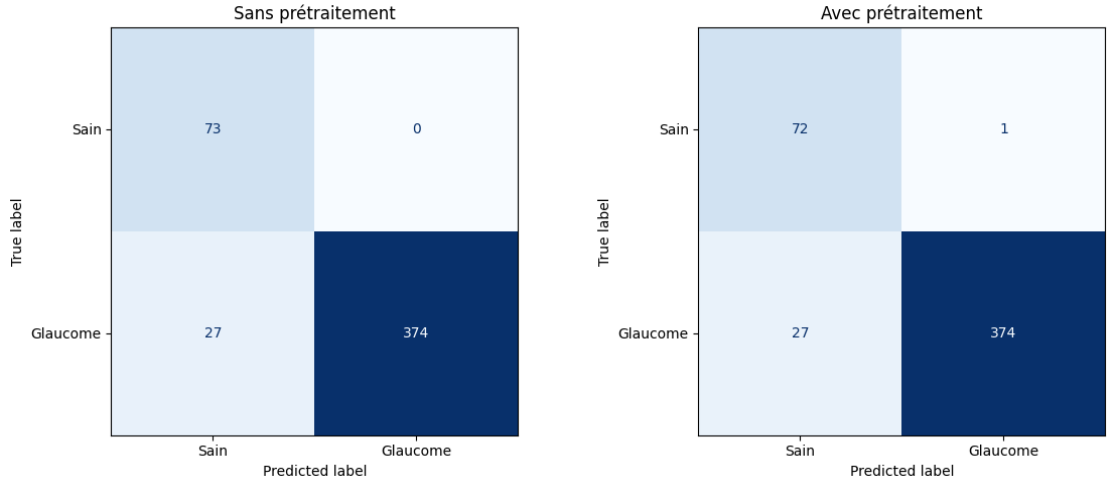


FIGURE 5.4 – Matrices de confusion du ResNet50 sur le jeu de test (second dataset)

Le tableau récapitulatif des performances et les courbes ROC (figure 5.5) montrent une exactitude globale de l'ordre de 94 % et une AUC de 0,982 sans prétraitement contre 0,980 avec prétraitement.

5.3 Résultats du ViT-B/16

5.3.1 Courbes d'apprentissage

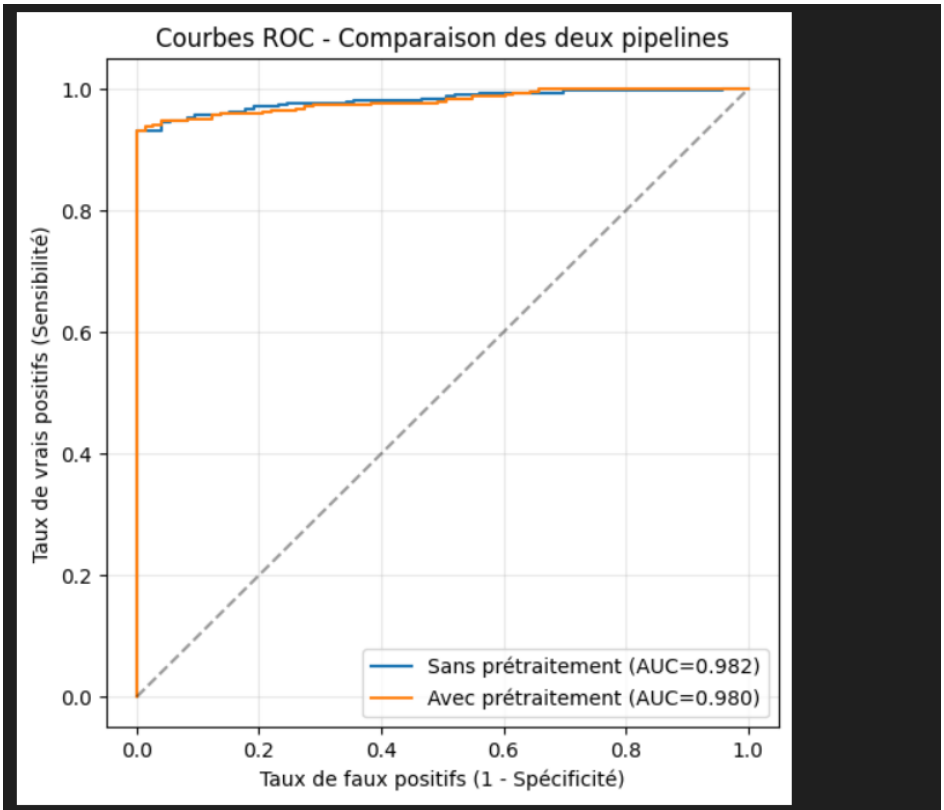
La figure 5.6 illustre l'évolution de la perte, de l'exactitude et de l'AUC de validation pour le ViT-B/16 sur le second dataset.

5.3.2 Performances sur le jeu de test

Les figures 5.7a, 5.7b et la synthèse globale détaillée sur la figure 5.8 présentent les matrices de confusion et les métriques (exactitude d'environ 94,7 % à 95,4 %, sensibilité proche de 0,945 et spécificité atteignant 1,000 avec le pipeline prétraité).

5.4 Fiabilité des étiquettes et discussion

L'analyse approfondie de la structure du second dataset a révélé des incohérences potentielles (présence de doublons inter-classes et de cas ambigus ou mal étiquetés). Bien que les modèles affichent des performances numériques élevées (AUC $\approx$ 0.98), ces bruits d'étiquettes soulignent la nécessité d'une vérification rigoureuse par des experts ophtalmologues avant toute application clinique réelle.



Pipeline	Accuracy	Sensibilité	Spécificité	Précision	F1	ROC-AUC
Sans prétraitement	0.943038	0.932668	1.000000	1.000000	0.965161	0.981963
Avec prétraitement	0.940928	0.932668	0.986301	0.997333	0.963918	0.980289

FIGURE 5.5 – Courbes ROC et performances du ResNet50 sur le second dataset

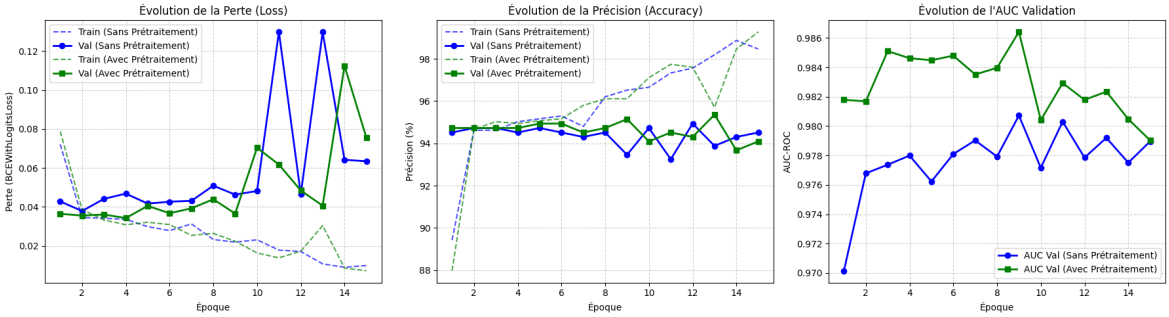
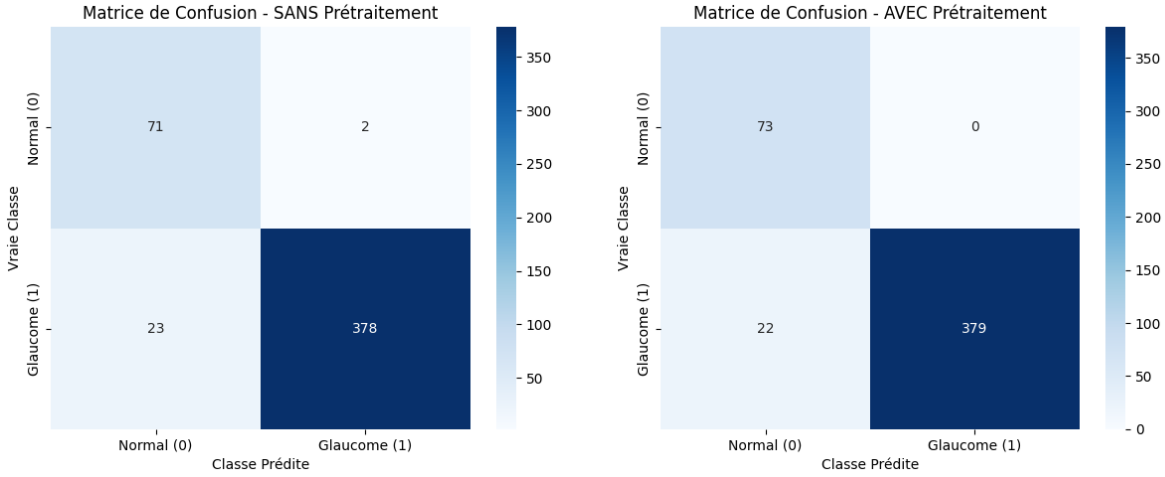


FIGURE 5.6 – Courbes d'apprentissage du ViT-B/16 sur le second dataset



(a) Sans prétraitement (b) Avec prétraitement

FIGURE 5.7 – Matrices de confusion du ViT-B/16 sur le jeu de test

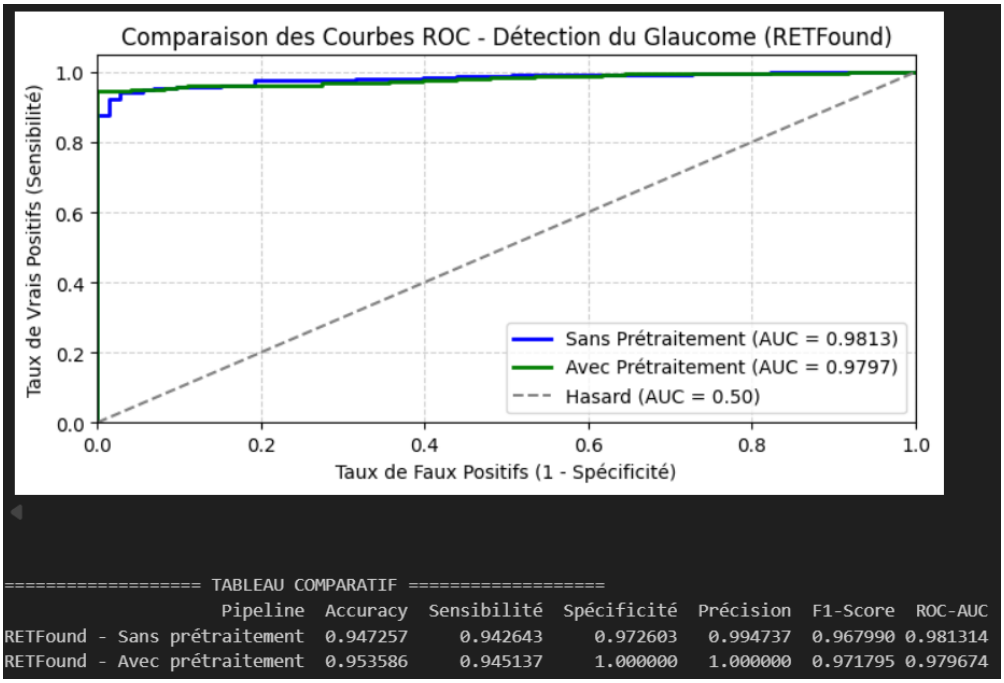


FIGURE 5.8 – Courbes ROC et métriques du ViT-B/16 sur le second dataset

5.5 Conclusion partielle

Sur ce second dataset hétérogène et déséquilibré, les deux architectures démontrent une forte robustesse avec des AUC supérieures à 0,97. Contrairement au dataset ACRIMA où le prétraitement améliorait nettement le ResNet50, les performances sur ce second corpus restent très stables entre les pipelines avec et sans prétraitement.

Chapitre 6

Discussion générale et conclusion

Ce chapitre synthétise les résultats croisés des deux jeux de données, discute la pertinence des choix méthodologiques et trace les perspectives d'amélioration future.

6.1 Discussion transversale

La confrontation des résultats sur ACRIMA et sur le second dataset met en lumière la complémentarité des approches CNN (ResNet50) et Transformer (ViT-B/16). Le ResNet50 bénéficie grandement d'un prétraitement par CLAHE sur des bases homogènes, tandis que le ViT-B/16 montre d'excellentes capacités de généralisation globale grâce à l'auto-attention, au prix toutefois d'un risque de surapprentissage rapide sur les petits volumes de données. La figure 6.1 récapitule cette comparaison globale.

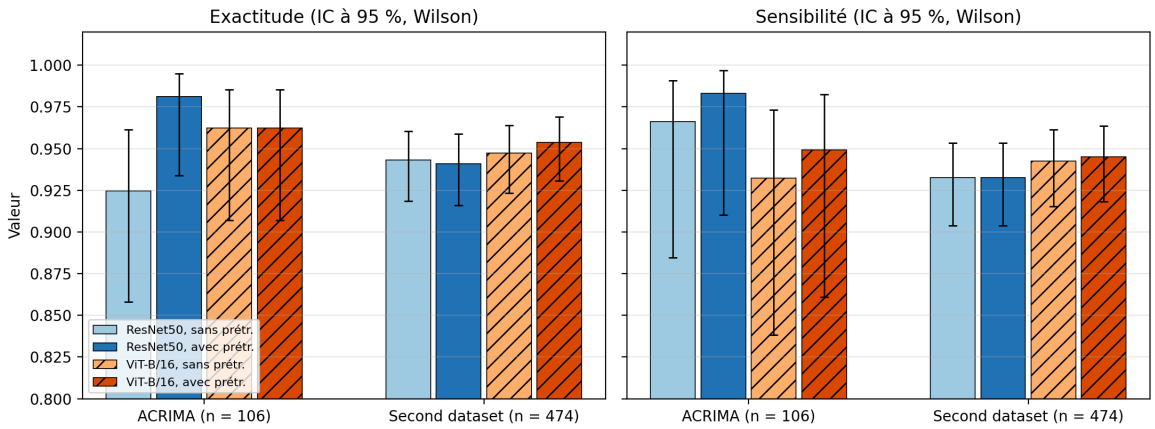


FIGURE 6.1 – Synthèse globale de la comparaison des performances sur les deux datasets

6.2 Conclusion générale et perspectives

Ce travail a permis de valider un pipeline complet de détection automatique du glaucome par apprentissage profond. Les perspectives incluent l'intégration de modèles

de fondation spécialisés comme RETFound sur des volumes plus larges, ainsi qu'un nettoyage approfondi des bases de données pour éliminer les biais d'étiquetage.

Bibliographie

[1] WEINREB, R. N., AUNG, T. et MEDEIROS, F. A. The Pathophysiology and Treatment of Glaucoma : A Review. *JAMA*, 2014, vol. 311, no 18, p. 1901–1911. DOI : 10.1001/jama.2014.3192.

[2] JONAS, J. B. et al. Glaucoma. *The Lancet*, 2017, vol. 390, p. 2183–2193. DOI : 10.1016/S0140-6736(17)31469-1.

[3] THAM, Y. C. et al. Global Prevalence of Glaucoma and Projections of Glaucoma Burden through 2040. *Ophthalmology*, 2014, vol. 121, no 11, p. 2081–2090. DOI : 10.1016/j.ophtha.2014.05.013.

[4] LITJENS, G. et al. A Survey on Deep Learning in Medical Image Analysis. *Medical Image Analysis*, 2017, vol. 42, p. 60–88. DOI : 10.1016/j.media.2017.07.005.

[5] TING, D. S. W. et al. Development and Validation of a Deep Learning System for Diabetic Retinopathy and Related Eye Diseases Using Retinal Images From Multiethnic Populations With Diabetes. *JAMA*, 2017, vol. 318, no 22, p. 2211–2223. DOI : 10.1001/jama.2017.18152.

[6] LI, Z. et al. Efficacy of a Deep Learning System for Detecting Glaucomatous Optic Neuropathy Based on Color Fundus Photographs. *Ophthalmology*, 2018, vol. 125, no 8, p. 1199–1206. DOI : 10.1016/j.ophtha.2018.01.023.

[7] DÍAZ-PINTO, A. et al. CNNs for Automatic Glaucoma Assessment Using Fundus Images : An Extensive Validation. *Biomedical Engineering Online*, 2019, vol. 18, article 29. DOI : 10.1186/s12938-019-0649-y.

[8] FU, H., CHENG, J., XU, Y., ZHANG, C., WONG, D. W. K., LIU, J. et CAO, X. Disc-Aware Ensemble Network for Glaucoma Screening From Fundus Image. *IEEE Transactions on Medical Imaging*, 2018, vol. 37, no 11, p. 2493–2501. DOI : 10.1109/TMI.2018.2837012.

[9] LECUN, Y., BENGIO, Y. et HINTON, G. Deep Learning. *Nature*, 2015, vol. 521, p. 436–444. DOI : 10.1038/nature14539.

[10] GOODFELLOW, I., BENGIO, Y. et COURVILLE, A. *Deep Learning*. MIT Press, 2016.

[11] RUMELHART, D. E., HINTON, G. E. et WILLIAMS, R. J. Learning Representations by Back-Propagating Errors. *Nature*, 1986, vol. 323, p. 533–536. DOI : 10.1038/323533a0.

[12] SRIVASTAVA, N. et al. Dropout : A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learning Research*, 2014, vol. 15, p. 1929–1958.

[13] KINGMA, D. P. et BA, J. Adam : A Method for Stochastic Optimization. *International Conference on Learning Representations*, 2015.

[14] LOSHCHILOV, I. et HUTTER, F. Decoupled Weight Decay Regularization. *International Conference on Learning Representations*, 2019.

[15] LECUN, Y. et al. Gradient-Based Learning Applied to Document Recognition. *Proceedings of the IEEE*, 1998, vol. 86, no 11, p. 2278–2324.

[16] IOFFE, S. et SZEGEDY, C. Batch Normalization : Accelerating Deep Network Training by Reducing Internal Covariate Shift. *International Conference on Machine Learning*, 2015.

[17] HE, K., ZHANG, X., REN, S. et SUN, J. Deep Residual Learning for Image Recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, p. 770–778. DOI : 10.1109/CVPR.2016.90.

[18] DENG, J. et al. ImageNet : A Large-Scale Hierarchical Image Database. *IEEE Conference on Computer Vision and Pattern Recognition*, 2009.

[19] VASWANI, A. et al. Attention Is All You Need. *Advances in Neural Information Processing Systems*, 2017, vol. 30.

[20] DOSOVITSKIY, A. et al. An Image is Worth 16x16 Words : Transformers for Image Recognition at Scale. *International Conference on Learning Representations*, 2021.

[21] HE, K. et al. Masked Autoencoders Are Scalable Vision Learners. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022.

[22] ZHOU, Y. et al. A Foundation Model for Generalizable Disease Detection from Retinal Images. *Nature*, 2023, vol. 622, p. 156–163. DOI : 10.1038/s41586-023-06555-x.

[23] PAN, S. J. et YANG, Q. A Survey on Transfer Learning. *IEEE Transactions on Knowledge and Data Engineering*, 2010, vol. 22, no 10, p. 1345–1359.

[24] YOSINSKI, J. et al. How Transferable Are Features in Deep Neural Networks ? *Advances in Neural Information Processing Systems*, 2014, vol. 27.

[25] POWERS, D. M. W. Evaluation : From Precision, Recall and F-Measure to ROC, Informedness, Markedness and Correlation. *Journal of Machine Learning Technologies*, 2011, vol. 2, no 1, p. 37–63.

[26] FAWCETT, T. An Introduction to ROC Analysis. *Pattern Recognition Letters*, 2006, vol. 27, no 8, p. 861–874. DOI : 10.1016/j.patrec.2005.10.010.

[27] HANLEY, J. A. et MCNEIL, B. J. The Meaning and Use of the Area under a Receiver Operating Characteristic (ROC) Curve. *Radiology*, 1982, vol. 143, no 1, p. 29–36.

[28] SAITO, T. et REHMSMEIER, M. The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. *PLOS ONE*, 2015, vol. 10, no 3, e0118432. DOI : 10.1371/journal.pone.0118432.

[29] WILSON, E. B. Probable Inference, the Law of Succession, and Statistical Inference. *Journal of the American Statistical Association*, 1927, vol. 22, no 158, p. 209–212.

[30] PIZER, S. M. et al. Adaptive Histogram Equalization and Its Variations. *Computer Vision, Graphics, and Image Processing*, 1987, vol. 39, no 3, p. 355–368.

[31] ZUIDERVELD, K. Contrast Limited Adaptive Histogram Equalization. In : HECKBERT, P. S. (dir.). *Graphics Gems IV*. Academic Press, 1994, p. 474–485.

[32] GONZALEZ, R. C. et WOODS, R. E. *Digital Image Processing*. 4e édition, Pearson, 2018.

[33] BAJWA, M. N. et al. G1020 : A Benchmark Retinal Fundus Image Dataset for Computer-Aided Glaucoma Detection. *Data in Brief*, 2020, vol. 29, article 105342.

[34] ZHANG, Z. et al. ORIGA-light : An Online Retinal Fundus Image Database for Glaucoma Analysis and Research. *Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, 2010.

[35] ORLANDO, J. I. et al. REFUGE Challenge : A Unified Framework for Evaluating Automated Methods for Glaucoma Assessment from Fundus Photographs. *Medical Image Analysis*, 2020, vol. 59, article 101570. DOI : 10.1016/j.media.2019.101570.

[36] ABADI, M. et al. TensorFlow : A System for Large-Scale Machine Learning. *12th USENIX Symposium on Operating Systems Design and Implementation*, 2016.

[37] PASZKE, A. et al. PyTorch : An Imperative Style, High-Performance Deep Learning Library. *Advances in Neural Information Processing Systems*, 2019, vol. 32.

[38] BRADSKI, G. The OpenCV Library. *Dr. Dobb's Journal of Software Tools*, 2000.

[39] PEDREGOSA, F. et al. Scikit-learn : Machine Learning in Python. *Journal of Machine Learning Research*, 2011, vol. 12, p. 2825–2830.

[40] WIGHTMAN, R. PyTorch Image Models. Dépôt logiciel, 2019. https://github.com/huggingface/pytorch-image-models.